

Armazenamento e Gestão de Dados com Data Lake e Data Lakehouse

59 %

Trilha

Fórum

✓ video 02:35

✓ Arquivos Usados Neste Capítulo pdf

✓ Bibliografia, Referências e Links Úteis pdf

13. Data Lakehouse - Convergência entre Data Lakes e Data Warehouses - Parte 1

✓ Introdução pdf

✓ Vantagens da Convergência - Por Que Um Data Lakehouse? ebook 02:43

✓ Arquitetura e Design de Um Data Lakehouse ebook 01:53

✓ Processos e Pipelines em Um Data Lakehouse ebook 01:51

✓ Segurança e Governança em Data Lakehouses ebook 02:06

✓ Lab 5 - Trabalhando com Databricks Para Construção de Catálogo Unificado de Dados



Processos e Pipelines em Um Data Lakehouse

Os processos e pipelines em um data lakehouse são projetados para ingerir, transformar, armazenar e disponibilizar dados de forma eficiente, suportando uma ampla gama de casos de uso, como análise de negócios, aprendizado de máquina e processamento de dados em tempo real. Esses pipelines são a espinha dorsal operacional de um data lakehouse, conectando diferentes etapas do ciclo de vida dos dados.

Etapas dos Processos em um Data Lakehouse

1. Ingestão de Dados

Os dados são coletados de várias fontes (bancos de dados, APIs, streams, dispositivos IoT, arquivos CSV ou JSON) e carregados para o data lakehouse. A ingestão pode ser feita de forma:

- Em lote: Dados coletados e processados em intervalos regulares.
- Em tempo real: Dados capturados e processados continuamente, utilizando ferramentas como Apache Kafka ou AWS Kinesis.

2. Transformação e Limpeza

Após a ingestão, os dados são transformados para garantir qualidade e consistência. Isso inclui:

- Normalização, padronização e conversão de formatos.
- Limpeza de dados, remoção de duplicatas e preenchimento de valores ausentes.
- Enriquecimento, combinando dados de diferentes fontes.
- Ferramentas como Apache Spark, Databricks ou serviços nativos de nuvem (AWS Glue, Azure Data Factory) são comuns nessa etapa.

3. Armazenamento e Organização

Os dados são organizados em camadas, permitindo diferentes níveis de processamento e consumo:

- Raw Layer: Armazena dados brutos em seu formato original.
- Cleansed Layer: Dados tratados e prontos para uso analítico.
- Curated Layer: Dados preparados para análises específicas ou modelos de aprendizado de máquina.
- Tecnologias como Delta Lake, Apache Iceberg ou Hudi garantem transações ACID e versionamento, facilitando a governança e consistência.

4. Indexação e Metadados


Os pipelines atualizam catálogos de dados (como Hive Metastore ou AWS Glue Catalog), permitindo consultas rápidas e otimizadas por mecanismos de query.

5. Consulta e Análise

Os dados processados são disponibilizados para análise por meio de ferramentas como SQL (Databricks SQL, Presto) ou interfaces de BI (Power BI, Tableau).

6. Machine Learning e Streaming Avançado

Pipelines especializados podem processar dados em tempo real para treinar ou atualizar modelos de aprendizado de máquina continuamente.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

?

?

?

?

?

?

?

?

?

?

?

?

?

?

?

?

?