

Armazenamento e Gestão de Dados com Data Lake e Data Lakehouse

67 %

Trilha

Fórum

- e Tarefas - Parte 1/3

video

05:41
- Lab 5 - Databricks Workspace - Criação de Workflows, Jobs e Tarefas - Parte 2/3

video

03:51
- Lab 5 - Databricks Workspace - Criação de Workflows, Jobs e Tarefas - Parte 3/3

video

02:57
- Lab 5 - Databricks Workspace - Ambiente de Computação e Vector Search

video

06:16
- Lab 5 - Databricks Workspace - SQL Editor e SQL Warehouses

video

05:33
- Lab 5 - Databricks Workspace - Data Engineering com Data Ingestion e Delta Live Tables

videobook

02:02
- Lab 5 - Databricks Workspace - Machine Learning e IA Generativa

videobook

01:16
- Lab 5 - Integração e Importação de Dados Para o Catálogo do Databricks Lakehouse - Parte 1/5


video

02:50
- Lab 5 - Integração e Importação de Dados Para o



Lab 5
Databricks Workspace - Data Engineering com Data Ingestion e Delta Live Tables

Data Engineering com Data Ingestion e Delta Live Tables no Databricks envolve a criação e gerenciamento eficientes de pipelines de dados modernos para integrar, processar e armazenar dados de maneira escalável e confiável.



? Suporte

? Suporte



Data Ingestion

Refere-se ao processo de ingestão de dados de diferentes fontes (bancos de dados, APIs, arquivos, etc.) para a plataforma Databricks. Esse processo pode ser realizado em tempo real (streaming) ou em batch. As principais características da Data Ingestion no Databricks incluem:

- Suporte a múltiplos formatos de dados, como JSON, CSV, Parquet e Avro.
- Conectores nativos para fontes como Kafka, Amazon S3, Azure Blob Storage e bancos de dados tradicionais.
- Integração com ferramentas de ETL e serviços de ingestão como Apache Nifi ou Apache Flume.

Delta Live Tables (DLT)

É uma funcionalidade do Databricks projetada para simplificar e automatizar a criação e o gerenciamento de pipelines de dados confiáveis. Ele se baseia no formato Delta Lake e permite transformar dados brutos em tabelas prontas para análise com as seguintes vantagens:

- Automação de Pipelines: Cria pipelines declarativos baseados em SQL ou Python, reduzindo a necessidade de escrever código complexo de ETL.
- Transformações Incrementais: Processa apenas os dados alterados ou novos, otimizando o desempenho.
- Validação e Qualidade de Dados: Inclui regras para garantir a integridade dos dados e detectar erros antes de comprometer o pipeline.
- Monitoramento e Auditoria: Fornece insights detalhados sobre o desempenho do pipeline e rastreabilidade dos dados.
- Governança Integrada: Combinado ao Unity Catalog, garante que dados em pipelines sigam políticas de acesso e conformidade.

Como Funciona na Prática

- Ingestão de Dados Brutos: Dados são ingeridos em tempo real ou em batch para uma camada inicial de armazenamento (ex.: bronze tables).
- Transformação e Enriquecimento: DLT aplica transformações, agregações e validações em várias etapas para produzir dados refinados (ex.: silver tables).
- Entrega de Dados Prontos: Os dados finais (gold tables) são disponibilizados para consumo em análises, relatórios ou modelos de machine learning.

Essa abordagem permite que engenheiros de dados criem pipelines robustos e escaláveis com menos esforço, garantindo a qualidade e governança dos dados desde a ingestão até o consumo final.


? Suporte

? Suporte



? Suporte

? Suporte



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

? Suporte

? Suporte