

15. Fundamentos do Delta Lake

|                                                                                  |                                                                 |             |
|----------------------------------------------------------------------------------|-----------------------------------------------------------------|-------------|
|   | Introdução                                                      | pdf         |
|   | Compreendendo o Conceito de Delta Lake                          | ebook 01:15 |
|   | Princípios ACID (Atomicity, Consistency, Isolation, Durability) | ebook 01:52 |
|   | Arquitetura do Delta Lake                                       | ebook 02:01 |
|   | Fluxo de Operações na Arquitetura                               | ebook 03:07 |
|   | Otimizações de Armazenamento e Consulta no Delta Lake           | ebook 02:31 |
|   | Cuidado Para Não Confundir - Delta Live Tables x Delta Lake     | ebook 00:38 |
|  | Lab 6 - Operações CRUD e Time Travel com Delta Lake             | pdf         |



Arquitetura do Delta Lake

A arquitetura do Delta Lake é uma camada de armazenamento de dados que adiciona recursos avançados a sistemas tradicionais de Data Lakes, permitindo transações ACID, controle de versão e alta performance em ambientes de grandes volumes de dados. Ela se integra de forma nativa com o Apache Spark e pode ser implementada sobre sistemas de armazenamento baseados em arquivos, como Amazon S3, Azure Data Lake ou HDFS.

Principais Componentes da Arquitetura do Delta Lake

**Camada de Dados Armazenados:** O Delta Lake utiliza formatos de armazenamento baseados em arquivos, como Parquet, para manter os dados organizados em tabelas. Esses arquivos são acessíveis por meio de operações analíticas e de processamento.

**Log de Transações:** O coração da arquitetura é o log de transações, que rastreia

todas as operações realizadas em uma tabela. Ele registra metadados sobre operações como inserções, atualizações e exclusões, garantindo transações ACID e versionamento dos dados.

O log é armazenado como arquivos JSON e fornece rastreabilidade completa das alterações. Cada alteração cria um novo "snapshot" da tabela, permitindo acesso a versões anteriores dos dados.

**Catálogo de Metadados:** O Delta Lake gerencia um catálogo de metadados que contém informações sobre o esquema das tabelas, índices e otimizações. Isso facilita a evolução do esquema (adição ou alteração de colunas) sem interromper operações.


**Transações ACID:** Asseguram que operações concorrentes, como leituras e escritas, sejam executadas com consistência. Se uma transação falhar, o log de transações reverte todas as mudanças, mantendo os dados no estado consistente anterior.

**Camada de Computação (Apache Spark):** O Delta Lake é projetado para ser executado sobre o Apache Spark, utilizando suas APIs para processamento paralelo e em larga escala. Isso permite executar transformações e análises diretamente sobre os dados armazenados.

**Otimizações de Leitura e Escrita:** O Delta Lake usa técnicas avançadas para melhorar o desempenho, incluindo:

- Compactação de arquivos pequenos em arquivos maiores para eficiência.
- Indexação para acelerar buscas e leituras.
- "Data Skipping", que ignora partes irrelevantes dos dados durante as leituras com base em critérios específicos.

**Integração com Ferramentas de Análise:** O Delta Lake permite que sistemas de BI, Machine Learning e outros pipelines de dados consumam os dados diretamente, sem necessidade de movimentação ou duplicação.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.



? Suporte



? Suporte

? Suporte



? Suporte

? Suporte