

Armazenamento e Gestão de Dados com Data Lake e Data Lakehouse

75 %

Trilha

Fórum

15. Fundamentos do Delta Lake

Introdução	pdf	
Compreendendo o Conceito de Delta Lake	ebook	01:15
Princípios ACID (Atomicity, Consistency, Isolation, Durability)	ebook	01:52
Arquitetura do Delta Lake	ebook	02:01
Fluxo de Operações na Arquitetura	ebook	03:07
Otimizações de Armazenamento e Consulta no Delta Lake	ebook	02:31
Cuidado Para Não Confundir - Delta Live Tables x Delta Lake	ebook	00:38
Lab 6 - Operações CRUD e Time Travel com Delta Lake	pdf	

Fluxo de Operações na Arquitetura

O fluxo de operações na arquitetura do Delta Lake representa o ciclo de vida dos dados desde a ingestão até a análise, com garantias de integridade e performance. Vamos detalhar cada etapa desse processo.

1- Ingestão de Dados: Dados podem ser ingeridos no Delta Lake a partir de diferentes fontes e formatos comuns, como:

- Arquivos CSV: Dados tabulares simples.
- JSON: Dados semiestruturados.
- Parquet: Formato otimizado para leitura e escrita.
- Outras Fontes: Bancos de dados, streams em tempo real (ex.: Apache Kafka), APIs, entre outros.

Após a ingestão, esses dados são salvos como arquivos no Data Lake (ex.: S3, Azure Blob Storage, HDFS). Essa flexibilidade permite integrar múltiplas fontes de dados

heterogêneas.

2- Conversão Para Tabelas Delta: O Delta Lake organiza os dados ingeridos em tabelas Delta. Isso inclui:

- Adicionar metadados sobre o esquema e a organização dos dados.
- Armazenar o log de transações associado à tabela para rastrear alterações.
- Possibilidade de compactação e reorganização dos arquivos para melhorar a eficiência.

A tabela Delta combina a flexibilidade de um Data Lake com a estrutura e consistência de um banco de dados.

3- Armazenamento no Log de Transações: Todas as operações realizadas na tabela Delta (inserções, atualizações, exclusões ou alterações no esquema) são registradas no log de transações:

- Cada operação cria um "commit" no log, descrevendo as alterações realizadas.
- O log de transações permite reverter para versões anteriores dos dados (controle de versão).
- Também garante que operações concorrentes não causem inconsistências (transações ACID).

Exemplo: Se uma operação falhar, o log permite desfazê-la e manter os dados no estado anterior.

4- Operações de Leitura e Escrita com Consistência: Durante as leituras e escritas, o Delta Lake consulta o log de transações para:

- Garantir que os dados acessados estejam consistentes.
- Evitar conflitos quando múltiplos usuários ou processos acessam a mesma tabela.
- Fornecer visões instantâneas (snapshots) dos dados, permitindo leitura de versões específicas.

Exemplo: Enquanto um processo escreve dados, outro processo pode continuar lendo a versão anterior sem interferência.

5- Otimização de Dados: O Delta Lake aplica automaticamente técnicas para melhorar a performance e gerenciar o armazenamento:

- Compactação de Arquivos: Arquivos pequenos são combinados em arquivos maiores para reduzir a fragmentação.
- Otimização de Layout: Os dados são reorganizados fisicamente para acelerar consultas (ex.: particionamento e ordenação por colunas usadas em filtros).
- Data Skipping: Durante consultas, partes dos dados irrelevantes são ignoradas com base em índices e estatísticas armazenadas.
- Vacuum: Arquivos obsoletos ou versões antigas dos dados podem ser removidos para liberar espaço.

6- Consulta e Análise: Os dados armazenados nas tabelas Delta podem ser consumidos diretamente por ferramentas de análise e visualização, como Power BI, Tableau ou bibliotecas de Machine Learning. Isso elimina a necessidade de copiar ou duplicar os dados para ambientes diferentes.

Exemplo de Fluxo:


- Um arquivo CSV com vendas diárias é carregado no Delta Lake.

- O sistema converte o CSV em uma tabela Delta, adicionando metadados e registrando a operação no log.

- Durante uma consulta para identificar vendas por região, o Delta Lake usa técnicas como compactação e particionamento para acelerar a análise.

- Se um analista precisa corrigir um erro de carregamento, ele pode consultar uma versão anterior da tabela (com base no log de transações) e corrigir o problema sem impactar usuários que estão lendo os dados.

Esse fluxo permite que o Delta Lake integre grandes volumes de dados de forma confiável e eficiente, simplificando o gerenciamento e a análise de dados.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

