

Armazenamento e Gestão de Dados com Data Lake e Data Lakehouse

75 %

Trilha

Fórum

15. Fundamentos do Delta Lake

Introdução	pdf	
Compreendendo o Conceito de Delta Lake	ebook	01:15
Princípios ACID (Atomicity, Consistency, Isolation, Durability)	ebook	01:52
Arquitetura do Delta Lake	ebook	02:01
Fluxo de Operações na Arquitetura	ebook	03:07
Otimizações de Armazenamento e Consulta no Delta Lake	ebook	02:31
Cuidado Para Não Confundir - Delta Live Tables x Delta Lake	ebook	00:38
Lab 6 - Operações CRUD e Time Travel com Delta Lake	pdf	



Otimizações de Armazenamento e Consulta no Delta Lake

O Delta Lake aplica diversas otimizações de armazenamento e consulta para melhorar a eficiência, a performance e a escalabilidade do processamento de dados. Essas otimizações garantem que operações de leitura e escrita sejam rápidas, mesmo com grandes volumes de dados e múltiplos usuários acessando o sistema simultaneamente.

Otimizações de Armazenamento

Compactação de Arquivos:

- Durante a ingestão de dados, especialmente em fluxos contínuos (streaming), arquivos pequenos são criados frequentemente.
- A compactação combina esses pequenos arquivos em arquivos maiores, reduzindo a fragmentação e melhorando o desempenho de leitura.

- Essa técnica é essencial porque sistemas baseados em arquivos, como HDFS ou S3, lidam melhor com um menor número de arquivos grandes do que com muitos arquivos pequenos.

Particionamento:

- Os dados podem ser particionados com base em colunas frequentemente usadas como filtros em consultas (por exemplo, partições por ano, mês ou região).
- Isso reduz o escopo dos dados analisados durante uma consulta, diminuindo o tempo de execução e o uso de recursos.

Vacuum:

- Remove arquivos antigos ou desnecessários que não são mais referenciados pelo log de transações.
- Isso libera espaço de armazenamento, garantindo que somente os dados necessários sejam mantidos.

Manutenção de Estatísticas e Índices:

- O Delta Lake coleta e armazena estatísticas de colunas (como valores mínimos e máximos) em metadados.
- Essas estatísticas são usadas para otimizar o planejamento de consultas e acelerar a execução.

Esquema Evolutivo:

- Suporta mudanças no esquema de forma incremental e eficiente, como adicionar ou alterar colunas, sem necessidade de recriar ou reorganizar os dados existentes.

Otimizações de Consulta

Data Skipping:

- Permite ignorar automaticamente partes dos dados durante as leituras com base nos valores de estatísticas coletadas.

Exemplo: Se uma consulta procura por vendas de 2022, o Delta Lake ignora arquivos que contêm apenas dados de 2021, reduzindo o número de leituras.

Reorganização de Dados (Optimize):

- O comando OPTIMIZE organiza fisicamente os dados para melhorar o desempenho de consultas.
- Os dados podem ser agrupados e ordenados com base em colunas frequentemente usadas, minimizando leituras desnecessárias.

Leitura Incremental (Streaming):

- Permite que apenas os dados adicionados ou modificados desde a última execução sejam lidos em fluxos contínuos.
- Isso é eficiente para casos de uso em tempo real, como dashboards ou análises de dados em streaming.

Caching:


- O Delta Lake pode armazenar em cache dados frequentemente acessados, acelerando consultas repetidas.
- Isso reduz leituras redundantes do sistema de arquivos subjacente.

Consulta de Versões (Time Travel):

- Oferece a capacidade de consultar versões históricas dos dados usando o log de transações.
- Isso permite análises baseadas em estados passados dos dados sem a necessidade de manter múltiplas cópias.

Suporte Nativo ao Spark Catalyst Optimizer:

- O Delta Lake se integra diretamente com o query optimizer do Apache Spark, aproveitando as otimizações automáticas para planejamento de consultas e execução paralela.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

