



Armazenamento e Gestão de Dados com Data Lake e Data Lakehouse

Melhores Práticas e Recomendações ao Usar o Databricks

Armazenamento e Gestão de Dados com Data Lake e Data Lakehouse

Aqui estão as melhores práticas e recomendações ao usar o Databricks para garantir eficiência, segurança e escalabilidade.

1. Gerenciamento de Clusters

- Use clusters de propósito único para isolar workloads diferentes e evitar interferências.
- Ative o escalonamento automático (Auto-scaling) para ajustar recursos dinamicamente com base na carga de trabalho.
- Programe o desligamento automático de clusters inativos para economizar custos.

2. Otimização de Dados

- Utilize o Delta Lake para garantir ACID, versionamento de dados e melhor desempenho em consultas.
- Empregue técnicas como Z-Ordering e Compactação de Arquivos para otimizar a leitura de grandes volumes de dados.
- Use caches (como Delta Cache) para reduzir a latência de consultas repetitivas.

3. Desenvolvimento de Notebooks

- Mantenha o código organizado, usando células de markdown para documentar e explicar blocos de código.
- Use parâmetros nos notebooks para facilitar a reutilização em diferentes contextos.
- Divida tarefas complexas em notebooks menores e conectados por workflows.

4. Gerenciamento de Metadados e Governança

- Centralize a gestão de metadados com o Unity Catalog para controle de acesso detalhado e organização dos dados.
- Classifique e rotule dados críticos para conformidade e governança.
- Audite regularmente o uso de dados para garantir segurança e conformidade regulatória.

5. Segurança e Controle de Acesso

- Utilize controle de acesso baseado em funções (RBAC) para limitar permissões de leitura, escrita e execução.
- Armazene senhas e credenciais no Databricks Secret Scope.
- Configure VPCs e regras de firewall para proteger redes e conexões externas.

Armazenamento e Gestão de Dados com Data Lake e Data Lakehouse

6. Otimização de Desempenho

- Minimize shuffles e ampliações desnecessárias ajustando partições e reparticionando adequadamente.
- Monitore e depure jobs usando o Spark UI para identificar gargalos.
- Use joins e filtros antecipadamente para reduzir o volume de dados processados.

7. Colaboração

- Promova a colaboração usando notebooks compartilhados e comentários em tempo real.
- Mantenha o versionamento de código integrado com ferramentas como Git.

8. Automação e Workflows

- Use o Databricks Workflows para agendar e automatizar jobs.
- Monitore e notifique falhas de jobs para corrigir rapidamente.


9. Gerenciamento de Custos

- Analise o uso de recursos regularmente usando relatórios integrados no Databricks.
- Use tags de recursos para rastrear custos por projeto ou equipe.

10. Aprendizado Contínuo

- Acompanhe atualizações do Databricks Runtime para aproveitar as últimas melhorias de desempenho.
- Consulte a documentação oficial e participe de treinamentos para equipes.

Essas práticas ajudam a aproveitar ao máximo a plataforma, reduzindo custos e aumentando a eficiência e a segurança.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.