

Modelagem, Implementação e Governança de Data Warehouses

94 %

Trilha

Fórum

9. Projeto 1 - Data Warehouse em Ambiente Local - Implementação

10. Extração, Transformação e Carga de Dados (ETL) com Airbyte e SQL - Parte 1

Introdução

Definindo o Processo - ETL x ELT

Traditional ETL x Modern Data Stack ETL

Lab 3 - Airbyte e SQL Para ETL no Data Warehouse em Ambiente Local

Lab 3 - Visão Geral

Lab 3 - Esquema da Solução Proposta - Parte 1/2

Lab 3 - Esquema da Solução Proposta - Parte 2/2

Lab 3 - Estrutura do Lab



Definindo o Processo - ETL x ELT

Os processos de ETL (Extract, Transform, Load) e ELT (Extract, Load, Transform) são duas abordagens fundamentais no campo da engenharia de dados, especialmente para a movimentação e gestão de grandes volumes de dados.

Ambas as metodologias são essenciais para o tratamento de dados em sistemas de armazenamento de dados (data warehouses e data lakes).

Vamos explorar cada uma delas para entender suas características e diferenças.



ETL (Extract, Transform, Load)

1. Extração: Os dados são extraídos de várias fontes, que podem ser sistemas transacionais, bancos de dados, arquivos CSV, APIs, entre outros. A extração é feita de maneira a minimizar o impacto sobre os sistemas de origem.

2. Transformação: Após a extração, os dados passam por uma série de transformações para garantir que estejam limpos, corretos e em formatos consistentes. Isso pode incluir limpeza, agregação, sumarização, validação e enriquecimento dos dados. A transformação é realizada antes de carregar os dados no sistema de destino para garantir que os dados estejam prontos para análises e decisões empresariais.

3. Carga: Finalmente, os dados transformados são carregados no data warehouse ou sistema de destino. Este passo geralmente é realizado em lotes (batch), podendo ocorrer em intervalos regulares (diário, semanalmente, etc.).

ELT (Extract, Load, Transform)

1. Extração: A extração é similar ao ETL, onde os dados são coletados de diversas fontes.

2. Carga: Ao contrário do ETL, no ELT os dados são carregados diretamente no sistema de destino, como um data lake ou data warehouse, sem transformações prévias. Isso significa que os dados são armazenados em sua forma bruta.


3. Transformação: As transformações são realizadas após os dados já estarem carregados no sistema de destino. Isso é possível graças à capacidade de processamento de sistemas modernos como BigQuery, Snowflake e Amazon Redshift, que são capazes de manipular grandes volumes de dados brutos diretamente no armazenamento.

Diferenças e Escolha

- Performance:** ELT pode ser mais rápido para grandes volumes de dados, pois aproveita a potência de processamento dos sistemas de armazenamento modernos.
- Flexibilidade:** ELT oferece mais flexibilidade, pois permite transformar os dados de acordo com as necessidades ao longo do tempo, sem a necessidade de reprocessar durante cada carga.
- Segurança e Conformidade:** ETL pode ser preferível quando os dados precisam ser rigorosamente limpos e validados antes de serem armazenados, para cumprir regulamentações de segurança e privacidade.

A escolha entre ETL e ELT depende de vários fatores, incluindo a natureza dos dados, os requisitos de processamento, as capacidades do sistema de armazenamento de dados e as necessidades de conformidade e segurança da organização.

Ambos os processos são fundamentais para a estratégia de dados de uma empresa e a escolha entre um e outro pode significar uma grande diferença na eficiência e eficácia das operações de dados.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.