

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

10 %

Trilha

Fórum

video

04:43

O Processo de Extração

video

06:05

O Processo de Transformação

video

07:47

O Processo de Carga

video

09:56

Python e Suas Bibliotecas Para ETL



ebook

01:56

Manipulação de Dados com Pandas



ebook

01:17

Trabalhando com JSON e XML em Python

ebook

01:04

Conexão com Bancos de Dados Usando SQLAlchemy

ebook

01:46

Automação de Pipelines de ETL

ebook

02:20

Logging e Monitoramento de ETLs

ebook

02:18



Data Science
Academy

Manipulação de Dados com Pandas

A manipulação de dados com a biblioteca Pandas em Python é uma habilidade fundamental na engenharia de dados. Pandas oferece estruturas de dados poderosas e flexíveis, como o DataFrame, que facilitam a manipulação e análise de dados.

Aqui estão algumas operações essenciais que você pode realizar com Pandas:

Leitura e Escrita de Dados

Pandas suporta vários formatos de arquivo, como CSV, Excel, JSON, SQL, entre outros.

Leitura de Dados:

`pd.read_csv('arquivo.csv')`, `pd.read_excel('arquivo.xlsx')`, etc.

Escrita de Dados:

`df.to_csv('arquivo.csv')`, `df.to_excel('arquivo.xlsx')`, etc.

Inspeção e Limpeza de Dados

Visualizar Dados:

`df.head()` para as primeiras linhas, `df.tail()` para as últimas.

Verificar Tipos de Dados:

`df.dtypes`.

Estatísticas Resumidas:

`df.describe()`.

Tratamento de Valores Ausentes:

`df.dropna()` para remover, `df.fillna(value)` para substituir.

Remover Duplicatas:

`df.drop_duplicates()`.

Seleção e Filtragem

Seleção de Colunas:

`df['coluna']` ou `df[['col1', 'col2']]`.

Seleção de Linhas por Índice:

`df.iloc[0]` (primeira linha), `df.loc['index']` (por índice nomeado).

Filtragem Condicional:

`df[df['coluna'] > valor]`.

Transformações e Agregações

Aplicar Funções:

`df['coluna'].apply(lambda x: x*2)`.

Agrupações e Resumos:

`df.groupby('coluna').sum()` ou `df.groupby('coluna').mean()`.

Unir e Combinar Dados:

`pd.merge(df1, df2, on='coluna')`, `df1.join(df2)`, `pd.concat([df1, df2])`.

Manipulação de Datas e Horas

Conversão de Strings para Datetime:

`pd.to_datetime(df['coluna'])`.

Extração de Componentes de Data:

`df['coluna'].dt.year`, `.dt.month`, `.dt.day`, etc.

Visualização de Dados

Pandas integra-se bem com bibliotecas de visualização como Matplotlib e Seaborn, permitindo gráficos direto dos DataFrames:

Plotagem Básica:


`df.plot()`, `df['coluna'].hist()`, etc.

Exemplo Prático:

```
1 import pandas as pd
2
3 # Lendo um arquivo CSV
4 df = pd.read_csv('arquivo.csv')
5
6 # Visualizando as primeiras linhas
7 print(df.head())
8
9 # Filtrando dados
10 filtered_df = df[df['idade'] > 30]
11
12 # Agrupando e calculando a média
13 mean_df = df.groupby('departamento')['salario'].mean()
14
15 # Salvando os resultados
16 mean_df.to_csv('media_salario_por_departamento.csv')
17
```

Essas são apenas algumas das operações básicas que você pode realizar com Pandas.

A biblioteca é extremamente rica em funcionalidades e sua flexibilidade a torna uma ferramenta indispensável para a engenharia de dados.



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte