

Trilha		Fórum
video		04:43
▶ O Processo de Extração	video	06:05
▶ O Processo de Transformação	video	07:47
▶ O Processo de Carga	video	09:56
📖 Python e Suas Bibliotecas Para ETL	ebook	01:56
📖 Manipulação de Dados com Pandas	ebook	01:17
📖 Trabalhando com JSON e XML em Python	ebook	01:04
📖 Conexão com Bancos de Dados Usando SQLAlchemy	ebook	01:46
📖 Automação de Pipelines de ETL	ebook	02:20
📖 Logging e Monitoramento de ETLs	ebook	02:18



Python e Suas Bibliotecas Para ETL

Python é uma escolha popular para a Engenharia de Dados, especialmente para tarefas de ETL (Extract, Transform, Load), devido à sua flexibilidade, facilidade de uso e uma vasta gama de bibliotecas disponíveis.

Aqui estão algumas das bibliotecas Python mais usadas para ETL:

1. Pandas:

Uma biblioteca essencial para a manipulação e análise de dados. Oferece estruturas de dados como DataFrame, que facilitam a manipulação de dados tabulares, permitindo filtrar, transformar e agregar dados de maneira eficiente.

2. NumPy:

Usada principalmente para computação numérica, é útil em ETL para manipulação de arrays e matrizes, além de fornecer funções matemáticas de alto nível.

3. SQLAlchemy:

Uma biblioteca SQL toolkit e Object-Relational Mapping (ORM) que facilita o acesso e a manipulação de bancos de dados de maneira agnóstica em relação ao tipo de banco de dados utilizado.

4. PySpark:

Parte do projeto Apache Spark, é usado para processamento de grandes volumes de dados. Permite que você escreva aplicações Spark usando Python, sendo ideal para operações que exigem alto desempenho e paralelismo.

5. Luigi:

Desenvolvido pelo Spotify, é uma biblioteca para construir pipelines de processamento de dados. É útil para organizar tarefas de ETL complexas, gerenciando dependências entre elas.

6. Apache Airflow:

Embora não seja uma biblioteca, mas sim uma plataforma, é amplamente usada em conjunto com Python para programar, organizar e monitorar fluxos de trabalho de ETL.

7. Dask:

Similar ao Pandas e NumPy, mas para computação paralela. É útil para trabalhar com datasets muito grandes que não cabem na memória de uma única máquina.


8. Beautiful Soup e Scrapy:

Usadas para web scraping, ou seja, extração de dados de websites, que podem ser usados como uma fonte de dados em processos de ETL.

9. Pandas-Profiling:

Uma biblioteca para geração de relatórios de análise exploratória de dados. Muito útil para compreender os dados durante a fase de transformação do ETL.

Essas bibliotecas, juntas, oferecem uma ampla gama de funcionalidades que facilitam diversas etapas do processo de ETL, desde a extração de dados de várias fontes, transformação e limpeza dos dados, até o carregamento dos dados transformados em um sistema de armazenamento de dados ou Data Warehouse.



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte