



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

Projeto 1

Pipeline PySpark Para Extrair, Transformar e Carregar Arquivos JSON em Banco de Dados




PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming



O Projeto 1 é uma solução de processamento de dados que utiliza o PySpark para implementar um pipeline ETL (Extract, Transform, Load). Este projeto é focado na manipulação eficiente de arquivos JSON, realizando a extração de dados desses arquivos, aplicando transformações necessárias e, finalmente, carregando os dados transformados em um banco de dados para armazenamento e análise posterior. É uma ferramenta valiosa para organizações que lidam com grandes volumes de dados em formato JSON e buscam otimizar suas operações de processamento de dados.

Os scripts estão ao final do capítulo. Bons estudos.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.