

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

20 %

Trilha

Fórum

5. PySpark Para Processamento Distribuído de Dados -
Parte 1



Introdução

pdf



Fundamentos e Componentes do Apache Spark

ebook

01:59



✓

Entendendo Paralelismo e Distribuição no Spark

ebook

01:53



Transformações e Ações em RDDs

ebook

02:07



Projeto 2 - 50 Scripts de Otimização de Processamento e Análise de Dados em Cluster Spark

pdf



Projeto 2 - Visão Geral - Vamos Trabalhar com 50 Scripts - Foi Isso Mesmo Que Você Leu!

video

02:48



Projeto 2 - Ajustando o Nível de Log do Cluster Spark

video

06:05



Projeto 2 - Inicializando o Cluster Spark



Entendendo Paralelismo e Distribuição no Spark

O Apache Spark é projetado para processar grandes conjuntos de dados de forma eficiente, explorando os conceitos de paralelismo e distribuição. Esses são princípios fundamentais para entender como o Spark opera. Vamos compreender isso em detalhes:

Paralelismo refere-se à execução simultânea de múltiplas tarefas. No contexto do Spark, significa dividir uma tarefa grande em sub-tarefas menores que podem ser executadas ao mesmo tempo em diferentes núcleos de processadores ou até mesmo em diferentes máquinas.

Os RDDs (Resilient Distributed Datasets) são divididos em várias partições. Cada partição pode ser processada em paralelo em um núcleo de CPU diferente. O número de partições de um RDD influencia diretamente o nível de paralelismo, pois cada partição pode ser processada simultaneamente.

Operações como map e reduce podem ser realizadas em paralelo nas partições. Cada partição é processada independentemente das outras.

Distribuição está relacionada à execução de processos em múltiplas máquinas de um cluster. O Spark foi projetado para escalar de uma única máquina a milhares de nós de computação.


O Spark utiliza um gerenciador de cluster (como YARN, Mesos ou Kubernetes) para distribuir e gerenciar tarefas através dos nós do cluster. O gerenciador de cluster aloca recursos como CPU e memória para os diferentes nós e garante que as tarefas sejam executadas de maneira eficiente.

Os RDDs (estruturas distribuídas de dados) são distribuídos através do cluster. Isso significa que diferentes partes do conjunto de dados estão localizadas em diferentes máquinas. Isso permite que o Spark processe grandes conjuntos de dados que não caberiam na memória de uma única máquina.

A distribuição também traz desafios como a tolerância a falhas. O Spark usa o conceito de RDD para reconstruir automaticamente partições em caso de falhas, garantindo a resiliência do sistema.

Quando combinados, paralelismo e distribuição permitem que o Spark processe grandes volumes de dados de forma rápida e confiável.

A execução paralela dentro de cada máquina, juntamente com a capacidade de distribuir a carga de trabalho em um cluster, torna o Spark uma ferramenta poderosa para processamento de dados em larga escala.



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.



🔍 Suporte



🔍 Suporte



🔍 Suporte



🔍 Suporte



🔍 Suporte



🔍 Suporte

