

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

20 %

Trilha

Fórum

5. PySpark Para Processamento Distribuído de Dados -
Parte 1

-  Introdução
pdf
-  Fundamentos e Componentes do Apache Spark
ebook 01:59
-  Entendendo Paralelismo e Distribuição no Spark
ebook 01:53
-  Transformações e Ações em RDDs
ebook 02:07
-  Projeto 2 - 50 Scripts de Otimização de Processamento e
Análise de Dados em Cluster Spark
pdf
-  Projeto 2 - Visão Geral - Vamos Trabalhar com 50 Scripts -
Foi Isso Mesmo Que Você Leu!
video 02:48
-  Projeto 2 - Ajustando o Nível de Log do Cluster Spark
video 06:05
-  Projeto 2 - Inicializando o Cluster Spark



Fundamentos e Componentes do Apache Spark

O Apache Spark é um sistema de processamento de dados em larga escala, conhecido por sua rapidez e capacidade de lidar com grandes conjuntos de dados. Vamos descrever seus fundamentos e componentes principais:

Resilient Distributed Dataset (RDD):

É a abstração fundamental do Spark, representando uma coleção imutável de objetos distribuídos através do cluster. Os RDDs podem ser criados de várias formas e são capazes de realizar operações como map, filter e reduce.

Directed Acyclic Graph (DAG):

O Spark otimiza as operações de RDD usando um grafo acíclico direcionado para planejar a execução. Esse recurso permite que o Spark otimize o plano de execução e minimiza o tráfego de rede e a leitura de disco.

?

Suporte

?

Suporte

Cluster Manager:

Responsável por alocar recursos para as aplicações Spark. Pode ser integrado a vários gerenciadores de cluster, como YARN, Mesos ou Kubernetes, além do próprio gerenciador de cluster do Spark.

Spark Core:

Contém a funcionalidade básica, incluindo componentes para tarefas de agendamento, memória, gerenciamento de falhas, etc. Oferece APIs para a construção de RDDs e operações de transformação e ação sobre eles.

Spark SQL:

Permite a execução de consultas SQL em dados estruturados. Integra-se com o Hive e suporta várias fontes de dados, como JSON, CSV, Parquet, etc.

Spark Streaming:

Habilita o processamento de streams de dados em tempo real. Funciona dividindo os dados em streams de micro-batches para realizar operações de RDD em tempo real.

MLlib (Machine Learning Library):

Biblioteca para aprendizado de máquina, oferecendo algoritmos comuns de aprendizado, como classificação, regressão, clustering, etc. Facilita a construção de pipelines de aprendizado de máquina escaláveis.

GraphX:

Para processamento de grafos e análise de grafos em larga escala. Permite a construção de grafos a partir de RDDs.

APIs de Linguagem:

O Spark oferece APIs em várias linguagens de programação, como Scala, Python e Java, facilitando seu uso por uma ampla gama de desenvolvedores. Oferece ainda uma interface que permite aos usuários executar operações Spark usando a linguagem R.


O Apache Spark se destaca pela sua capacidade de processar grandes volumes de dados de maneira rápida e eficiente, sua versatilidade em suportar diferentes tipos de operações de dados (batch, streaming, Machine Learning, processamento de grafos) e sua facilidade de integração com outras ferramentas e plataformas de dados.

?

Suporte

?

Suporte



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.

?

Suporte

?

Suporte

?

Suporte

?

Suporte