

▶	Projeto 2 - Criando Dataframe a Partir de Dicionário com Map - Parte 2/2	video	05:40
▶	Projeto 2 - Top N	video	03:52
▶	Projeto 2 - Amostragem	video	05:56
📖	Projeto 2 - Objeto Row	ebook	01:03
📖	Projeto 2 - Agregação e Estatísticas	ebook	00:57
📖	Projeto 2 - Conversão Map-Coluna-Map	ebook	01:26
📄	Arquivos Usados Neste Capítulo	pdf	🔗
📄	Bibliografia, Referências e Links Úteis	pdf	



Agregação e Estatísticas

Agregação

Agregação no PySpark se refere ao processo de combinar valores de várias linhas em um único valor. Isso é útil para resumir grandes conjuntos de dados e obter insights sobre as informações.

O PySpark fornece diversas funções de agregação para calcular valores estatísticos como soma, média, mediana, desvio padrão, máximo, mínimo, quartis, etc.

✔ Funções de Agregação:

Funções básicas:


- **sum()** - Soma os valores de uma coluna.
- **mean()** - Calcula a média dos valores de uma coluna.
- **min()** - Encontra o valor mínimo de uma coluna.
- **max()** - Encontra o valor máximo de uma coluna.

Funções avançadas:

- **stddev()** - Calcula o desvio padrão dos valores de uma coluna.
- **skewness()** - Calcula a assimetria dos valores de uma coluna.
- **kurtosis()** - Calcula a curtose dos valores de uma coluna.
- **quantile()** - Calcula os quantis de uma coluna.
- **approxQuantile()** - Calcula os quantis aproximados de uma coluna.

✔ Exemplos de Funções de Agregação no PySpark:

```
1 # Soma de todas as idades
2 df.agg({"idade": "sum"})
3
4 # Média da altura por gênero
5 df.groupby("genero").agg({"altura": "mean"})
6
7 # Quantis da coluna "salario"
8 df.agg({"salario": "quantile", "quantiles": [0.25, 0.5, 0.75]})
```



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.



? Suporte



? Suporte



? Suporte



? Suporte



? Suporte



? Suporte

