

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

21 %

Trilha

Fórum

5. PySpark Para Processamento Distribuído de Dados - ^
Parte 1

-  Introdução
pdf
-  Fundamentos e Componentes do Apache Spark
ebook 01:59
-  Entendendo Paralelismo e Distribuição no Spark
ebook 01:53
-  Transformações e Ações em RDDs
ebook 02:07
-  Projeto 2 - 50 Scripts de Otimização de Processamento e Análise de Dados em Cluster Spark
pdf
-  Projeto 2 - Visão Geral - Vamos Trabalhar com 50 Scripts - Foi Isso Mesmo Que Você Leu!
video 02:48
-  Projeto 2 - Ajustando o Nível de Log do Cluster Spark
video 06:05
-  Projeto 2 - Inicializando o Cluster Spark



Transformações e Ações em RDDs

No Apache Spark, as operações realizadas em RDDs (Resilient Distributed Datasets) são categorizadas em duas classes principais: Transformações e Ações. Essas operações são fundamentais para entender como o Spark processa dados.

Transformações

Transformações são operações que criam um novo RDD a partir de um RDD existente. Elas são aplicadas de forma "lazy", ou seja, não são executadas imediatamente. A execução ocorre apenas quando uma ação é realizada.

Características:

- Lazy Evaluation: A transformação define uma nova operação no DAG (Directed Acyclic Graph) do Spark, mas não é computada até que seja necessária.
- Imutabilidade: Cada transformação cria um novo RDD, pois os RDDs são

imutáveis. Isso significa que uma vez criados, eles não podem ser alterados.

Exemplos Comuns:

- map(): Retorna um novo RDD aplicando uma função a cada elemento do RDD original.
- filter(): Cria um novo RDD contendo apenas os elementos que satisfazem uma condição.
- flatMap(): Similar ao map, mas cada elemento de entrada pode ser mapeado para 0 ou mais elementos de saída.
- union(): Retorna um novo RDD contendo elementos de ambos os RDDs.
- distinct(): Elimina elementos duplicados no RDD.

Ações

Ações são operações que devolvem um valor final após processar os dados de um RDD. Ao contrário das transformações, as ações forçam a execução das operações de RDDs.

Características:


- Triggering Computations: As ações são responsáveis por iniciar a computação no Spark, ativando a execução do DAG.
- Produzindo Resultados: Ao final de uma ação, o Spark retorna um resultado concreto, que pode ser um valor, uma coleção de valores ou a escrita em um sistema de armazenamento.

Exemplos Comuns:

- collect(): Retorna todos os elementos do RDD como um array. Cuidado com o uso em RDDs muito grandes, pois pode causar problemas de memória.
- count(): Retorna o número de elementos no RDD.
- take(n): Retorna um array com os primeiros n elementos do RDD.
- reduce(func): Agrega os elementos do RDD usando uma função que recebe dois argumentos e retorna um novo valor.
- saveAsTextFile(path): Escreve o RDD em um arquivo de texto no sistema de arquivos, HDFS ou outro sistema de armazenamento compatível.

Fluxo de Trabalho

No fluxo de trabalho do Spark, normalmente as transformações são usadas para preparar e moldar os dados, enquanto as ações são utilizadas para obter resultados ou saídas concretas. A combinação dessas operações permite que o Spark processe grandes volumes de dados de forma eficiente, aproveitando a execução distribuída e o paralelismo.



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte