

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

33 %

TrilhaFórum

- video

07:31
- Projeto 2 - Parallelize

video

04:00
- Projeto 2 - Time Diff e Timestamp

ebook

00:55
- Projeto 2 - Window Functions no Spark

ebook

01:29
- Projeto 2 - Conclusão

video

02:21
- Arquivos Usados Neste Capítulo

pdf
- Bibliografia, Referências e Links Úteis

pdf

8. Checkpoint de Conhecimento

▼

9. Preparação do Ambiente de Trabalho - Multi-Node Cluster Spark e HDFS

▼



Window Functions no Spark

As Window Functions no Spark são ferramentas poderosas que permitem realizar cálculos complexos em subconjuntos de dados relacionados, sem a necessidade de agrupar os dados inteiramente. Elas são úteis para executar operações como cálculo de médias móveis, somas acumuladas, ranking e diferenciais dentro de uma janela definida de linhas.

Principais características e usos das Window Functions no Spark:

Definição de Janelas

As janelas são definidas usando a classe Window, que especifica como particionar e ordenar as linhas sobre as quais a função de janela será aplicada.

Uma janela pode ser definida por uma ou mais colunas de partição (partitionBy) e uma ordem específica (orderBy).

Tipos Comuns de Window Functions

Agregações: Funções como sum, avg, min, max, que podem ser aplicadas em uma janela de dados.

Ranking: Funções como rank, dense_rank, row_number, que atribuem classificações a filas dentro da janela.

Funções de deslocamento: Funções como lead e lag, que acessam valores de outras filas dentro da janela.

Funções de janela: Funções específicas como cume_dist (distribuição acumulada) e ntile (distribuição em quantis).

Exemplos de Aplicações

Cálculo de médias móveis: Usar funções de agregação dentro de uma janela deslizante para calcular a média de valores em um intervalo de tempo.


Somas acumuladas: Calcular uma soma progressiva dos valores.

Ranking de vendas: Determinar a posição de vendedores com base em suas vendas dentro de cada região.

Análise de eventos: Analisar diferenças de tempo entre eventos consecutivos.

As Window Functions são fundamentais para análise de dados complexa e detalhada, permitindo manipulações e cálculos que não seriam possíveis apenas com funções de agregação tradicionais.

O script 50 traz exemplos de uso das Window Functions no Spark.



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte

?

Suporte