

Introdução	pdf	
Vamos Criar o Segundo de Um Total de 3 Clusters Spark Deste Curso	video	04:14
O Que é Armazenamento Distribuído?	ebook	01:29
Modos de Gerenciamento de Cluster Spark	ebook	02:04
Gerenciamento de Cluster com YARN	ebook	02:36
Instalação e Configuração do Multi-Node Cluster Spark e HDFS - Parte 1/12	video	05:04
Instalação e Configuração do Multi-Node Cluster Spark e HDFS - Parte 2/12	video	04:22

Gerenciamento de Cluster com YARN

O YARN (Yet Another Resource Negotiator) é uma peça fundamental do ecossistema Hadoop, atuando como um sistema de gerenciamento de recursos que permite que várias aplicações de processamento de dados compartilhem um cluster comum de forma eficiente.

O Apache Spark, quando executado no YARN, aproveita essa capacidade para gerenciar recursos de maneira dinâmica e escalável.



Componentes do YARN

1. ResourceManager (RM):

- O RM é o serviço que aloca recursos e gerencia os aspectos de alto nível do cluster, como o agendamento de jobs e o monitoramento de recursos.
- Ele possui dois componentes principais: o Scheduler, que aloca recursos entre todas as aplicações; e o ApplicationsManager, que gerencia o ciclo de vida das aplicações submetidas ao cluster.

2. NodeManager (NM):

- Cada máquina no cluster tem um NM, que é responsável por monitorar o consumo de recursos (CPU, memória, disco, rede) e reportar ao ResourceManager.
- O NM também é responsável por gerenciar os contêineres de aplicações que executam as tarefas processadas.

Integração do Spark com YARN

I. Modo Cliente vs. Modo Cluster:

- No Modo Cliente, o driver do Spark é executado na máquina local que submeteu a aplicação, enquanto os executores são gerenciados pelo YARN no cluster. Isso é útil para aplicações interativas como o uso do Spark Shell.
- No Modo Cluster, tanto o driver quanto os executores são executados dentro de contêineres gerenciados pelo YARN no cluster. Esse modo é preferido para jobs de produção ou aplicações que não exigem interatividade.

II. Submissão de Jobs:

- Os jobs do Spark são submetidos ao YARN através do comando spark-submit com a configuração --master yarn. Durante a submissão, você pode especificar recursos como a quantidade de memória e núcleos de CPU para o driver e para os executores.


III. Alocação Dinâmica:

- O Spark no YARN suporta alocação dinâmica de executores, que permite que o Spark adicione ou remova executores dinamicamente com base na carga de trabalho. Isso ajuda a melhorar a utilização de recursos do cluster.
- Para habilitar a alocação dinâmica, você deve configurar a propriedade spark.dynamicAllocation.enabled como true e garantir que o serviço de shuffle externo do Spark esteja habilitado.

Vantagens do Uso do YARN

- **Eficiência:** O YARN permite que múltiplas aplicações de diferentes frameworks compartilhem um único cluster, o que melhora a utilização dos recursos.
- **Escalabilidade:** O YARN facilita a gestão de grandes clusters, permitindo que as organizações escalem suas operações de processamento de dados de acordo com a demanda.
- **Flexibilidade:** O YARN suporta uma variedade de aplicações, não se limitando apenas ao Spark, o que proporciona flexibilidade para usar o mesmo cluster para diferentes tecnologias de processamento de dados.

O gerenciamento de um cluster Spark com YARN requer uma compreensão das necessidades de recursos das suas aplicações e a capacidade de configurar e ajustar as propriedades do Spark e do YARN para otimizar tanto o desempenho quanto a utilização de recursos.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.