

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

41 %

Trilha

Fórum

HDFS - Parte 7/12
video 06:53

▶ Instalação e Configuração do Multi-Node Cluster Spark e
HDFS - Parte 10/12
video 01:46

📖 Instalação e Configuração do Multi-Node Cluster Spark e
HDFS - Parte 11/12
✓ videobook 01:56

📖 Instalação e Configuração do Multi-Node Cluster Spark e
HDFS - Parte 12/12
videobook 00:40

📄 Arquivos Usados Neste Capítulo
pdf

📄 Bibliografia, Referências e Links Úteis
pdf


10. Módulo Especial - Assistentes Pessoais Baseados
em IA

11. Limpeza e Processamento de Dados em Batch com
PySpark SQL - Parte 1



Instalação e Configuração do Multi-Node Cluster Spark e
HDFS - Parte 11/12

O uso de um cluster Spark com HDFS (Hadoop Distributed File System) e YARN (Yet Another Resource Negotiator) é apropriado para vários casos de uso, especialmente quando se lida com grandes volumes de dados e é necessário processamento distribuído.



🔍

🔍 Suporte

🔍 Suporte

Aqui estão alguns casos de uso comuns de um cluster Spark com HDFS e YARN:

1. Processamento de Big Data

ETL (Extract, Transform, Load): Transformação e limpeza de grandes volumes de dados antes de carregá-los em sistemas de armazenamento ou bancos de dados.

Análise de Logs: Processamento de logs de servidor, logs de aplicativos ou logs de transações para monitoramento, detecção de fraudes ou auditoria.

2. Análise em Tempo Real

Streams de Dados: Processamento em tempo real de dados de streaming usando Spark Streaming. Isso é útil para detecção de anomalias, análise de redes sociais, e monitoramento de IoT.

Processamento de Eventos: Análise de eventos em tempo real, como cliques em sites, transações financeiras, e eventos de sensores.

3. Machine Learning e Inteligência Artificial

Treinamento de Modelos: Treinamento de modelos de Machine Learning em grandes datasets distribuídos, utilizando bibliotecas como MLlib do Spark.

Inferência em Tempo Real: Aplicação de modelos treinados para fazer previsões em tempo real sobre dados em streaming.

4. Análise de Dados Complexos

Graph Processing: Análise de dados que podem ser representados como grafos, usando a biblioteca GraphX do Spark. Isso é útil em casos como análise de redes sociais, bioinformática e análise de relações entre entidades.

5. Consultas e Agregações em Larga Escala

Business Intelligence: Consultas e agregações complexas em grandes volumes de dados para suporte a decisões empresariais. Spark SQL é frequentemente utilizado para esse propósito.

Data Warehousing: Análise de dados armazenados em data warehouses, permitindo a combinação de dados estruturados e não estruturados.

6. Integração e Transformação de Dados

Data Integration: Integração de dados provenientes de diversas fontes, como bases de dados relacionais, sistemas NoSQL e arquivos CSV ou JSON armazenados no HDFS.

Data Cleansing: Limpeza e transformação de dados para prepará-los para análise ou para uso em outras aplicações.

🔍


🔍 Suporte

🔍 Suporte

🔍

🔍 Suporte

🔍 Suporte



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.

🔍

🔍 Suporte

🔍 Suporte