



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

Projeto 3

Pipeline de Limpeza e Transformação Para Aplicações de IA com PySpark SQL

PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming




No Projeto 3 vamos criar um pipeline de limpeza e transformação de dados usando PySpark SQL e então treinar a avaliar modelos de Machine Learning no cluster Spark. Os dados serão carregados do ambiente distribuído com HDFS e o resultado do processamento será salvo em formato Parquet. Os dados foram gerados com base no dataset disponível no link abaixo:

<https://www.kaggle.com/datasets/iamsouravbanerjee/airline-dataset/data>

Neste projeto vamos também explorar os conceitos de experimentação e execução no ambiente Spark.

Dados e scripts estão ao final do capítulo. Bons estudos.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.