

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

51 %

Trilha

Fórum

10. Módulo Especial - Assistentes Pessoais Baseados em IA


11. Limpeza e Processamento de Dados em Batch com PySpark SQL - Parte 1

Introdução	pdf	
O Que São Dados em Batch?	ebook	01:03
Limpeza e Tratamento de Dados Faltantes	ebook	01:45
Desnormalização e Normalização de Dados	ebook	02:09
View Temporárias vs. Tabelas Persistentes	ebook	02:02
Executando SQL com PySpark	ebook	02:10



Desnormalização e Normalização de Dados

No PySpark, tanto a normalização quanto a desnormalização de dados são técnicas importantes que se aplicam dependendo do objetivo da análise ou do sistema em que os dados serão utilizados.



Supporte

Supporte

Normalização de Dados

Normalização refere-se ao processo de estruturação de um banco de dados para reduzir a redundância e melhorar a integridade dos dados. Ela envolve a divisão de grandes tabelas em tabelas menores e a definição de relações entre elas através de chaves estrangeiras. Os benefícios incluem:

- **Redução de redundância:** Armazenamento eficiente dos dados ao evitar a duplicação.
- **Melhoria da integridade:** Atualizações, inserções e exclusões são mais consistentes e menos propensas a gerar erros.

No PySpark, você não realiza a normalização no sentido tradicional de bancos de dados relacionais, mas pode estruturar seus DataFrames de maneira que mimetizem esse comportamento.

Por exemplo, você pode manter chaves estrangeiras e dividir os dados em múltiplos DataFrames, assegurando que eles sejam combinados (join) somente durante as operações de análise.

Desnormalização de Dados

Desnormalização é o processo de reestruturação de um banco de dados para melhorar o desempenho de leitura, combinando tabelas e eliminando a necessidade de alguns joins. É comum em ambientes como data warehouses, onde o desempenho de leitura é prioritário. Os benefícios incluem:

- **Consultas mais rápidas:** Menos joins podem resultar em uma velocidade de consulta maior.
- **Simplificação de consultas:** A estrutura de dados é geralmente mais fácil de entender e manipular.

No PySpark, a desnormalização pode ser realizada combinando múltiplos DataFrames em um único DataFrame, usando operações de join. Poer exemplo:

```
>> df1 = spark.createDataFrame([(1, "Alice"), (2, "Bob")], ["id", "name"])
df2 = spark.createDataFrame([(1, "Python"), (2, "Spark")], ["id", "skill"])


# Desnormalização
df_joined = df1.join(df2, "id")
```

Esta operação combina dois DataFrames em um, agregando informações relacionadas para facilitar análises mais completas e rápidas.

Quando Usar Cada Técnica?

- **Normalização** é mais adequada para fases de modelagem e design de banco de dados, especialmente quando a integridade dos dados é uma prioridade e a escrita de dados é frequente.
- **Desnormalização** é geralmente preferida em ambientes de análise e relatórios, onde a performance de leitura é crucial e a frequência de atualizações de dados é relativamente baixa.

✔ No contexto de análise de dados com PySpark, frequentemente você executará uma forma de desnormalização para preparar seus dados para análise, garantindo que as operações de leitura e as agregações sejam otimizadas para performance.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

Supporte

Supporte