

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

51 %

Trilha

Fórum

8. Checkpoint de Conhecimento

9. Preparação do Ambiente de Trabalho - Multi-Node
Cluster Spark e HDFS

10. Módulo Especial - Assistentes Pessoais Baseados
em IA

11. Limpeza e Processamento de Dados em Batch com
PySpark SQL - Parte I

Introdução
pdf

O Que São Dados em Batch?
ebook

01:03

Limpeza e Tratamento de Dados Faltantes
ebook

01:45

Desnormalização e Normalização de Dados
ebook

02:09



Limpeza e Tratamento de Dados Faltantes

No contexto do **PySpark**, a limpeza e o tratamento de dados faltantes são passos essenciais para garantir a qualidade e a precisão dos modelos de dados.

Técnicas Comumente Utilizadas Para Tratar Dados Faltantes no PySpark

1. Remoção de Linhas:

Essa é a abordagem mais direta. Você pode remover qualquer linha que contenha valores nulos, o que é efetivo quando a quantidade de dados faltantes é pequena e não impacta a integridade do conjunto de dados.

```
>> df = df.na.drop()
```

Para remover linhas onde determinadas colunas específicas têm dados faltantes, você pode especificar as colunas:

```
>> df = df.na.drop(subset=["coluna1", "coluna2"])
```

2. Preenchimento de Valores Faltantes:

Você pode substituir os valores faltantes por um valor específico, como zero, a média ou a mediana das colunas. O PySpark oferece métodos convenientes para isso.

Para substituir todos os valores faltantes por um valor específico:

```
>> df = df.na.fill(0) # Substitui por zero
```

Para substituir valores faltantes em colunas específicas com diferentes valores:

```
>> df = df.na.fill({"coluna1": 0, "coluna2": "desconhecido"})
```

Se você deseja usar a média ou mediana, precisa calculá-las primeiro e depois aplicar o **fill**:

```
>> from pyspark.sql.functions import mean

mean_val = df.select(mean(df["coluna"])).collect()[0][0]
df = df.na.fill(mean_val, ["coluna"])
```

3. Interpolação:

Embora o PySpark não forneça funções diretas de interpolação como o pandas, você pode criar uma lógica customizada para interpolar valores com base em outras linhas ou utilizando modelos estatísticos.


4. Uso de Indicadores:

Outra técnica é adicionar uma coluna indicadora que mostra se o valor original estava faltando. Isso pode ser útil em modelagens preditivas para capturar a importância da ausência de dados.

```
>> from pyspark.sql.functions import col, when

df = df.withColumn("was_missing", when(col("coluna").isNull(),
1).otherwise(0))
```

Essas são algumas das técnicas básicas para tratar dados faltantes no PySpark. A escolha da técnica adequada pode depender do contexto específico do seu problema, da quantidade de dados faltantes e da importância de cada coluna para suas análises ou modelos preditivos.



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.



? Suporte

? Suporte



? Suporte

? Suporte



? Suporte

? Suporte



? Suporte

? Suporte