

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

51 %

Trilha

Fórum

8. Checkpoint de Conhecimento

9. Preparação do Ambiente de Trabalho - Multi-Node
Cluster Spark e HDFS

10. Módulo Especial - Assistentes Pessoais Baseados
em IA

11. Limpeza e Processamento de Dados em Batch com
PySpark SQL - Parte 1

Introdução
pdf

O Que São Dados em Batch?
ebook

01:03

Limpeza e Tratamento de Dados Faltantes
ebook

01:45

Desnormalização e Normalização de Dados
ebook

02:09



O Que São Dados em Batch?

Dados em batch referem-se a coleções de dados que são processados e manipulados em grandes blocos, em vez de serem tratados individualmente ou em tempo real. Este método de processamento de dados é geralmente utilizado quando é viável coletar um conjunto de dados antes de começar o processamento. Vamos detalhar alguns aspectos importantes:


Coleta de Dados: Os dados são acumulados durante um período definido, que pode ser de minutos, horas ou até dias, dependendo da necessidade e da aplicação.

Processamento: Após a coleta, os dados são processados como um único lote. Isso pode envolver operações como limpeza, transformação, análise e outras manipulações.

Eficiência e Escalabilidade: O processamento em batch é eficiente para grandes volumes de dados, pois as operações podem ser otimizadas e executadas sem a

necessidade de resposta imediata. Também é mais fácil de escalar, pois os recursos podem ser alocados e gerenciados de maneira controlada.

Aplicações Típicas: Análise de dados históricos, geração de relatórios periódicos, atualizações em massa em sistemas de banco de dados, e processamentos que não requerem interação em tempo real com os usuários finais.



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.

? Suporte
? Suporte

? Suporte
? Suporte