

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

52 %

Trilha


Fórum

✓	ebook	01:45
📖	Desnormalização e Normalização de Dados	
✓	ebook	02:09
📖	View Temporárias vs. Tabelas Persistentes	
✓	ebook	02:02
📖	Executando SQL com PySpark	
✓	ebook	02:10
📖	Uso de Built-in Functions no PySpark	
✓	ebook	02:09
📄	Projeto 3 - Pipeline de Limpeza e Transformação Para Aplicações de IA com PySpark SQL	
pdf		
▶	Projeto 3 - Visão Geral	
video		02:17
▶	Projeto 3 - Experimentação x Execução	
video		06:10
▶	Projeto 3 - Estrutura do Projeto	
video		02:50
▶	Projeto 3 - Como Realizar Experimentação com o Cluster	

Uso de Built-in Functions no PySpark

Funções built-in no PySpark são pré-definidas e otimizadas para processar e analisar dados de forma eficiente dentro do ambiente do Apache Spark.

Elas cobrem uma ampla gama de funcionalidades, desde operações simples até complexas transformações de dados. Essas funções são parte integrante da biblioteca PySpark e são projetadas para serem usadas diretamente em DataFrames e RDDs.



💡 Categorias de Funções Built-in

As funções built-in no PySpark podem ser categorizadas em vários grupos, dependendo do tipo de operação que realizam:

1. Funções de String:

Manipulam e modificam campos de texto, como alterar o caso de letras ou extrair substrings.

2. Funções Matemáticas:

Realizam cálculos numéricos, incluindo operações aritméticas básicas, funções trigonométricas, e estatísticas.

3. Funções de Data e Hora:

Facilitam o trabalho com datas e tempos, permitindo operações como extração de componentes de data, cálculo de diferenças entre datas, e formatação.

4. Funções de Agregação:

Usadas para realizar cálculos agregados, como soma, média, mínimo e máximo, que são especialmente úteis em operações de agrupamento.

5. Funções de Janela:

Oferecem suporte para cálculos complexos em "janelas" de dados, permitindo análises sequenciais ou baseadas em grupos.

6. Funções Condicionais e de Nulos:

Permitem criar lógicas condicionais dentro de consultas e tratar dados faltantes de maneira eficaz.

💡 Vantagens das Funções Built-in

1. Otimização Automática: As funções são otimizadas pelo Spark para executar operações de forma eficiente em grandes conjuntos de dados distribuídos. Isso inclui otimizações de execução e uso eficiente de recursos.

2. Simplicidade e Conveniência: Facilitam a escrita de transformações de dados sem a necessidade de escrever código complexo e verboso. Elas oferecem uma maneira direta e expressiva de implementar lógicas de dados.


3. Escalabilidade: Como o Spark distribui o processamento de dados em vários nós de um cluster, essas funções ajudam a manter a escalabilidade e o desempenho, mesmo com volumes de dados muito grandes.

💡 Aplicação Prática

Na prática, essas funções são usadas para preparar e transformar dados para análise, limpeza de dados, e geração de insights.

Elas são essenciais para o processamento eficiente de grandes datasets em ambientes distribuídos, como típicos em big data e análise de dados em escala.

A funções built-in no PySpark são ferramentas fundamentais para qualquer pessoa que trabalhe com processamento e análise de dados usando o Apache Spark, proporcionando uma forma poderosa e eficiente de manipular grandes volumes de dados.



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.