

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

51 %

Trilha

Fórum

10. Módulo Especial - Assistentes Pessoais Baseados em IA

11. Limpeza e Processamento de Dados em Batch com PySpark SQL - Parte 1

Introdução pdf

O Que São Dados em Batch? ebook 01:03

Limpeza e Tratamento de Dados Faltantes ebook 01:45

Desnormalização e Normalização de Dados ebook 02:09

View Temporárias vs. Tabelas Persistentes ebook 02:02

Executando SQL com PySpark ebook 02:10



View Temporárias vs. Tabelas Persistentes

No PySpark, tanto views temporárias quanto tabelas persistentes são estruturas utilizadas para organizar e manipular dados de forma eficiente. Cada uma tem suas características e usos ideais, dependendo dos requisitos da tarefa de processamento de dados.

Views Temporárias

Uma view temporária no PySpark é uma tabela virtual que você pode consultar durante uma sessão Spark. Ela não é armazenada fisicamente e é temporária, o que significa que desaparece quando a sessão é encerrada.

Aqui estão alguns detalhes sobre views temporárias:

- **Não são armazenadas:** Existem apenas na memória durante a sessão do Spark.

- **Consultas eficientes:** Úteis para segmentar um DataFrame grande ou complexo em partes menores para consultas frequentes, sem a sobrecarga de I/O de dados físicos.

- **Criação e uso:**

```
df.createOrReplaceTempView("view_name")
spark.sql("SELECT * FROM view_name")
```

Tabelas Persistentes

Tabelas persistentes são físicas e armazenadas no sistema de armazenamento do Spark, como HDFS, Amazon S3 ou em um sistema de arquivos local. Elas são úteis para armazenar dados processados para uso futuro, persistindo além das sessões do Spark.

Características incluem:

- **Armazenamento durável:** Os dados são salvos fisicamente, o que significa que eles persistem após o término da sessão do Spark.
- **Ideal para grandes conjuntos de dados:** Útil para armazenar grandes volumes de dados que são utilizados em várias análises ao longo do tempo.

- **Criação e uso:**

```
df.write.saveAsTable("table_name")
```


Comparativo

- **Performance:** Views temporárias não têm o custo de I/O de gravação e leitura de disco, o que as torna mais rápidas para acesso e manipulação durante a sessão, mas menos úteis para dados que precisam ser reutilizados em várias sessões.
- **Escopo:** Views temporárias são locais a uma sessão do Spark e desaparecem quando a sessão é fechada, enquanto tabelas persistentes são salvas no disco e podem ser acessadas em sessões futuras.

Onde Usar

- **Views temporárias** são ideais para análises ad-hoc, experimentos rápidos e transformações intermediárias de dados que não precisam ser reutilizadas após o fim da sessão.
- **Tabelas persistentes** são melhores para dados processados que são usados repetidamente em várias análises, relatórios ou aplicações de Machine Learning.

O uso de uma ou outra dependerá fortemente das necessidades específicas de desempenho, durabilidade e acesso dos dados em seus projetos de análise de dados e ciência de dados com PySpark.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.



🔍 Suporte

🔍 Suporte



🔍 Suporte

🔍 Suporte



🔍 Suporte

🔍 Suporte



🔍 Suporte

🔍 Suporte