

PySpark e Apache Kafka Para
Processamento de Dados em Batch e
Streaming

54 %

Trilha

Fórum

- video

04:11
- Projeto 3 - Exploração e Limpeza dos Dados em Batch - Parte 5/5

video

05:25
- Projeto 3 - Concatenando os Datasets e Preparando o Dataset Final

video

04:45
- Projeto 3 - Engenharia de Atributos

videobook

00:29
- Projeto 3 - Pré-Processamento com String Indexer e One Hot Encoder - Parte 1/2

videobook

01:03
- Projeto 3 - Pré-Processamento com String Indexer e One Hot Encoder - Parte 2/2

video

03:03
- Projeto 3 - Criando o Pipeline de Pré-Processamento

video

05:41
- Projeto 3 - Ajustando o Número de Partições


videobook

01:19
- Projeto 3 - Pipeline de Treinamento do Modelo de IA com PySpark em Ambiente Distribuído - Parte 1/5




Projeto 3
Pré-Processamento com String Indexer e One Hot
Encoder - Parte 1/2

No PySpark, StringIndexer e OneHotEncoder são ferramentas usadas para lidar com dados categóricos, convertendo-os em um formato que pode ser processado por algoritmos de Machine Learning.




StringIndexer: Ele converte valores categóricos de string em valores numéricos inteiros. Cada categoria é mapeada para um índice baseado na frequência de ocorrência, onde a categoria mais frequente recebe o índice 0, a segunda mais frequente recebe 1, e assim por diante. Esse método é útil quando você precisa transformar rótulos de texto em uma representação numérica para uso em modelos que requerem entrada numérica, como algoritmos de regressão ou classificação.

OneHotEncoder: Após a conversão de categorias em índices pelo StringIndexer, o OneHotEncoder transforma esses índices numéricos em vetores binários, onde cada posição do vetor corresponde a uma categoria. Apenas uma posição do vetor tem o valor 1 (indicando a categoria presente), enquanto as demais têm o valor 0. Isso é útil para evitar que o modelo interprete a ordem dos índices como tendo algum tipo de relação ou hierarquia.




Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.



Supporte

Supporte



Supporte

Supporte

Supporte

Supporte