

PySpark e Apache Kafka para processamento de dados em lote e streaming

56%

Trilha

Fórum

|                                                               |       |
|---------------------------------------------------------------|-------|
| video                                                         | 05:10 |
| Projeto 4 - Executando o Projeto - Parte 2/3                  | 05:14 |
| Projeto 4 - Executando o Projeto - Parte 3/3                  | 04:19 |
| Projeto 4 - Analisando os Resultados                          | 04:39 |
| Projeto 4 - Conclusão                                         | 02:39 |
| Ponto de verificação sem PySpark Streaming                    | 01:23 |
| Integração do Spark Streaming com Fontes de Dados Externas    | 02:26 |
| Monitoramento e depuração de aplicações de streaming de dados | 01:40 |
| Estratégias de Contrapressão e Rate Limiting                  | 01:30 |



Integração do Spark Streaming com Fontes de Dados Externas

A integração do Spark Streaming com fontes de dados externas é uma capacidade essencial que permite extrair, processar e analisar fluxos de dados em tempo real.

O Spark Streaming pode se conectar a uma ampla variedade de fontes de dados externas, como sistemas de mensagens, bancos de dados e sistemas de arquivos distribuídos, para receber dados em tempo real.



Supporte



Principais Fontes e Formas de Integração:

1. Apache Kafka:

**Apache Kafka** é uma das integrações mais populares do Spark Streaming. O Spark pode extrair dados de tópicos do Kafka em tempo real, processá-los em micro-lotes e, em seguida, enviar os resultados para outra fonte, como bancos de dados ou sistemas de arquivos.

A integração é feita através de conectores nativos do Spark Streaming, como **KafkaUtils.createDirectStream** , que permite um consumo eficiente de dados e controle de offsets.

2. Sistemas de Mensageria (RabbitMQ, Amazon Kinesis):

Além do Kafka, o Spark Streaming pode se integrar com outras plataformas de mensagens como **RabbitMQ** e **Amazon Kinesis**, que também fornecem fluxos de dados contínuos.

Essas integrações permitem consumir dados de linhas ou tópicos em tempo real para processamento distribuído e escalável. O Kinesis, em particular, é amplamente utilizado para ingestão de dados em pipelines baseados na nuvem.

3. Arquivos em Tempo Real (HDFS, S3, Azure Blob Storage):

O Spark Streaming pode monitorar diretórios em sistemas de arquivos distribuídos, como **HDFS**, **Amazon S3** e **Azure Blob Storage** , para detectar novos arquivos que são gerados continuamente.

Os dados são processados assim que os arquivos são salvos nessas fontes. Essa abordagem é útil quando os dados são capturados como logs ou arquivos em lote que são atualizados periodicamente.

4. Bancos de Dados Relacionais e NoSQL:

Embora os bancos de dados relacionais e NoSQL sejam geralmente usados para persistir dados, eles também podem ser fontes de dados para o Spark Streaming.

Usando conectores como **JDBC** , é possível consultar dados de bancos como **MySQL** e **PostgreSQL** . Além disso, bancos NoSQL como Cassandra e MongoDB oferecem integração com o Spark para que dados de streams possam ser lidos e processados em tempo real.

5. Soquetes:

O Spark Streaming oferece suporte à transferência de dados diretamente de soquetes de rede, o que é útil para cenários simples onde dados são transmitidos através de conexões **TCP/UDP** .


O uso de sockets é comum para processar fluxos de dados simples ou em tempo real, como dados de sensores, logs, ou mensagens.

Essas integrações permitem que o Spark Streaming seja altamente flexível e adaptável a diferentes tipos de fontes de dados, permitindo a criação de pipelines de processamento de dados em tempo real em uma ampla variedade de cenários empresariais e industriais.

Supporte



Supporte



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

Supporte



Supporte

