

PySpark e Apache Kafka para processamento de dados em lote e streaming

56%

Trilha

Fórum

14. Limpeza e Processamento de Dados em Tempo Real com PySpark Streaming - Parte 2

Introdução	pdf	
Vamos aplicar aprendizado de máquina em streaming de dados?	video	01:57
Projeto 4 - Conceitos Fundamentais do PySpark Streaming	e-book	01:53
Projeto 4 - DStreams e Micro-Lotes	e-book	00:54
Projeto 4 - Tratamento e Limpeza de Dados em Stream	e-book	01:54
Projeto 4 - Windowed Operations e Stateful Processing	e-book	02:15
Projeto 4 - Construindo o Módulo de Processamento de Stream - Parte 1/7	video	04:28
Projeto 4 - Construindo o Módulo de Processamento de		



Projeto 4
Conceitos Fundamentais do PySpark Streaming

PySpark Streaming é uma extensão do PySpark que permite processar fluxos contínuos de dados em tempo real, dividindo-os em micro-lotes para processamento distribuído.

Ele integra a capacidade do Apache Spark de lidar com grandes volumes de dados de maneira paralela e escalável, aplicando-a a dados que chegam de fontes como Kafka, soquetes ou sistemas de filas de mensagens.



?

Suporte

?

Suporte



Principais Conceitos do PySpark Streaming

1. **DStream (Discretized Stream):** Representa um fluxo contínuo de dados, onde os dados em tempo real são divididos em pequenos intervalos de tempo chamados micro-lotes. Cada microlote é tratado como um RDD (Resilient Distributed Dataset), e o processamento é feito de forma distribuída.
2. **Processamento de microlotes:** PySpark Streaming processa dados em pequenas porções chamadas microlotes. Isso significa que, embora você esteja lidando com fluxos contínuos de dados, ele os agrupa em intervalos discretos para processamento, o que facilita a execução de operações paralelas e distribuídas.
3. **Receptores:** São responsáveis por capturar dados de fontes externas, como Kafka, soquetes ou sistemas de filas de mensagens, e repassá-los para o sistema de streaming. Os Receptores podem ser confiáveis ou não, dependendo da necessidade de confirmar a entrega dos dados.
4. **Operações de janela:** Permitem agregar e analisar os dados dentro de uma janela de tempo. Isso possibilita realizar cálculos e gerar insights sobre os dados que chegam em diferentes intervalos temporais, como somas, médias, ou contágios de eventos.
5. **Operações com estado:** PySpark Streaming permite manter o estado dos dados entre os microlotes. Isso é útil para cenários onde você precisa monitorar informações em tempo real, como contagens cumulativas ou detecção de padrões.
6. **Checkpointing:** O PySpark Streaming utiliza checkpoints para armazenar dados intermediários e garantir a resiliência em casos de falhas. Isso é importante em cenários críticos onde é necessário recuperar o estado e continuar o processamento sem perda de dados.

✔ Esses conceitos formam a base para criar pipelines de processamento de dados em tempo real com PySpark Streaming, oferecendo flexibilidade para lidar com grandes volumes de dados com baixa latência.

?

Suporte

?

Suporte



?

Suporte

?

Suporte




?

Suporte

?

Suporte



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.