

PySpark e Apache Kafka para processamento de dados em lote e streaming

56%

Trilha

Fórum

14. Limpeza e Processamento de Dados em Tempo Real com PySpark Streaming - Parte 2

- Introdução pdf
- Vamos aplicar aprendizado de máquina em streaming de dados? video 01:57
- Projeto 4 - Conceitos Fundamentais do PySpark Streaming e-book 01:53
- Projeto 4 - DStreams e Micro-Lotes e-book 00:54
- Projeto 4 - Tratamento e Limpeza de Dados em Stream e-book 01:54
- Projeto 4 - Windowed Operations e Stateful Processing e-book 02:15
- Projeto 4 - Construindo o Módulo de Processamento de Stream - Parte 1/7 video 04:28
- Projeto 4 - Construindo o Módulo de Processamento de



Projeto 4 DStreams e Micro-Lotes

DStreams (Discretized Streams) e Micro-Batches são conceitos centrais no PySpark Streaming:

✎ Fluxo de dados:

Representa um fluxo contínuo de dados que é processado em pequenos intervalos de tempo. Ao invés de processar os dados em tempo real contínuo, o DStream divide o fluxo em segmentos temporais chamados micro-lotes, que são transformados e processados como RDDs (Resilient Distributed Datasets) internamente. Cada DStream é essencialmente uma sequência de RDDs no tempo.

? Suporte


? Suporte



✔ Micro-Lotes:

São pequenos lotes de dados coletados de um intervalo de tempo contínuo em um DStream. Eles tornam o processamento de dados em tempo real possível ao transformar o fluxo contínuo em pequenos pedaços processáveis. Cada microlote contém os dados acumulados durante o intervalo de tempo definido e é processado de forma distribuída pelo PySpark.

Esses conceitos permitem que o PySpark Streaming execute operações de processamento distribuídas em dados contínuos com eficiência, permitindo tanto análises em tempo real quanto a manutenção de baixa latência.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

? Suporte

? Suporte

