

|                                                                        |                                                                         |       |
|------------------------------------------------------------------------|-------------------------------------------------------------------------|-------|
| PySpark e Apache Kafka para processamento de dados em lote e streaming |                                                                         |       |
| <div></div>                                                            |                                                                         | 56%   |
| <div>TrilhaFórum</div>                                                 |                                                                         |       |
| <div></div>                                                            | Projeto 4 - Construindo o Módulo de Processamento de Stream - Parte 4/7 | 06:55 |
| <div></div>                                                            | Projeto 4 - Construindo o Módulo de Processamento de Stream - Parte 5/7 | 03:19 |
| <div></div>                                                            | Projeto 4 - Construindo o Módulo de Processamento de Stream - Parte 6/7 | 06:52 |
| <div></div>                                                            | Projeto 4 - Construindo o Módulo de Processamento de Stream - Parte 7/7 | 05:08 |
| <div></div>                                                            | Projeto 4 - Persistência de Dados Processados em Tempo Real             | 02:40 |
| <div></div>                                                            | Projeto 4 - Salvando o Resultado em Banco de Dados                      | 04:23 |
| <div></div>                                                            | Projeto 4 - Executando o Projeto - Parte 1/3                            | 05:10 |
| <div></div>                                                            | Projeto 4 - Executando o Projeto - Parte 2/3                            | 05:14 |



## Projeto 4

### Persistência de Dados Processados em Tempo Real

A **persistência de dados** processados em tempo real é uma prática em sistemas de streaming, como o PySpark Streaming, para garantir que os dados processados estejam disponíveis para análises posteriores, auditorias ou outros usos.



🔍 Suporte

🔍 Suporte



No contexto do **PySpark Streaming**, existem várias maneiras de persistir os dados processados em tempo real:

#### 📖 1. Armazenamento em Bancos de Dados Relacionais e NoSQL:

- **Relacionais:** Os dados podem ser persistidos em bancos de dados como MySQL, PostgreSQL, SQL Server ou SQLite. Usar JDBC é uma abordagem comum para inserir os dados processados em tabelas de banco de dados.
- **NoSQL:** Para dados que precisam ser armazenados de maneira mais flexível, bancos NoSQL como MongoDB, Cassandra ou HBase são opções terapêuticas. Eles são especialmente úteis quando você precisa lidar com grandes volumes de dados não estruturados ou semiestruturados.

#### 📖 2. Data Lakes e Data Warehouses:

- **Data Lakes:** Ferramentas como Amazon S3, Azure Data Lake ou Google Cloud Storage podem ser usadas para persistir dados processados como arquivos estruturados (parquet, JSON, CSV) que podem ser posteriormente aplicados por sistemas de Big Data.
- **Data Warehouses:** Plataformas como Amazon Redshift, Google BigQuery ou Snowflake são usadas para armazenar grandes volumes de dados processados para análise agregada ou construção de relatórios complexos.

#### 📖 3. HDFS (Sistema de Arquivos Distribuidos Hadoop):

Para sistemas que utilizam clusters Hadoop, os dados processados podem ser gravados diretamente no HDFS. Isso é comum em pipelines de Big Data, onde os dados em tempo real são usados para análise e aprendizado de máquina em larga escala.

#### 📖 4. Sistemas de Mensageria (Kafka, RabbitMQ):

Em alguns casos, após o processamento inicial, os dados são enviados novamente para sistemas de mensagens como Apache Kafka ou RabbitMQ, que são redistribuídos para outros serviços ou aplicações para processamento adicional ou persistência posterior.

#### 📖 5. Armazenamento em Tabelas Distribuidas (Cassandra, HBase):

Para garantir alta disponibilidade e baixa latência, os dados processados podem ser persistidos em bancos de dados distribuídos como Apache Cassandra ou HBase, permitindo que grandes volumes de dados sejam consultados e atualizados em tempo real.

#### 📖 6. Sistemas de Arquivos:


Dependendo do volume e da criticidade dos dados, eles podem ser salvos diretamente em sistemas de arquivos distribuídos ou locais, em formatos como JSON, CSV, Parquet ou Avro, para serem consumidos posteriormente por outros sistemas ou pipelines de dados.

#### 📖 7. Pesquisa elástica:

Para cenários em que é necessário persistir dados com finalidade específica de buscas rápidas ou visualizações em dashboards, como o Kibana, o Elasticsearch é uma excelente opção. Dados de logs ou medições em tempo real são frequentemente persistidos no Elasticsearch para permitir consultas rápidas.

- ✔ **Essas técnicas permitem que dados processados em tempo real sejam persistentes de forma eficiente e estejam disponíveis para análises futuras, relatórios ou integrações com outros sistemas.**

A escolha do método de persistência dependerá da natureza dos dados, da infraestrutura disponível e dos requisitos de desempenho.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

🔍 Suporte

🔍 Suporte



🔍 Suporte

🔍 Suporte



🔍 Suporte

🔍 Suporte



🔍 Suporte

🔍 Suporte



🔍 Suporte

🔍 Suporte