

Introdução

pdf

Vamos aplicar aprendizado de máquina em streaming de dados?

video

01:57

Projeto 4 - Conceitos Fundamentais do PySpark Streaming

e-book

01:53

Projeto 4 - DStreams e Micro-Lotes

e-book

00:54

Projeto 4 - Tratamento e Limpeza de Dados em Stream

e-book

01:54

Projeto 4 - Windowed Operations e Stateful Processing

e-book

02:15

Projeto 4 - Construindo o Módulo de Processamento de Stream - Parte 1/7

video

04:28


Projeto 4 - Construindo o Módulo de Processamento de



Projeto 4

Tratamento e Limpeza de Dados em Stream

O tratamento e limpeza de dados em streams, como no contexto do PySpark Streaming, envolve várias técnicas para garantir que os dados recebidos de fontes em tempo real sejam válidos, consistentes e prontos para uso.



?

Suporte

?

Suporte



Principais Práticas de Tratamento e Limpeza de Dados em Stream

1. Filtragem de dados irrelevantes ou inválidos: Muitas vezes, os dados de streams podem conter informações que não são úteis ou estão corrompidas. Utilizando operações de filtro em DStreams, você pode remover valores nulos, entradas duplicadas ou qualquer dado fora dos padrões esperados.

2. Conversão de tipos de dados: Os dados em streams podem chegar em formatos inconsistentes, como strings representando números ou dados. A conversão de tipos é essencial para garantir que todos os dados não tenham formato adequado para o processamento. Isso pode ser feito transformando cada RDD de um DStream.

3. Tratamento de valores nulos ou ausentes: Os dados recebidos em tempo real podem conter valores ausentes ou nulos. Para lidar com isso, podem ser aplicadas técnicas como preenchimento de valores padrão (imputação) ou exclusão de registros incompletos, dependendo do caso de uso.

4. Normalização e padronização: Para dados numéricos, pode ser importante garantir que todos os valores estejam em uma faixa ou escala comum. As operações de normalização podem ser aplicadas em cada microlote para manter os dados consistentes ao longo do tempo.

5. Desduplicação: Fluxos de dados podem gerar registros duplicados, especialmente em sistemas distribuídos. Para evitar a contagem ou processamento de dados repetidos, você pode usar funções para identificar e remover duplicatas com base em chaves ou IDs exclusivos.

6. Agregação e enriquecimento de dados: Em alguns casos, pode ser necessário adicionar dados em uma janela de tempo ou enriquecer os dados em fluxo com informações de fontes externas. Operações de join ou windowing podem ser aplicadas a DStreams para criar dados mais significativos e completos.



Essas técnicas garantem que os dados em tempo real sejam processados de forma eficiente e limpa, permitindo análises e ações precisas sobre os dados recebidos.

?

Suporte

?

Suporte




?

Suporte

?

Suporte



Equipe DSA

Continue trilhando uma excelente
jornada de aprendizagem.

?

Suporte

?

Suporte

