

PySpark e Apache Kafka para processamento de dados em lote e streaming

56%

Trilha

Fórum

Projeto 4

Conceitos Fundamentais do PySpark Streaming

e-book

01:53

Projeto 4

DStreams e Micro-Lotes

e-book

00:54

Projeto 4

Tratamento e Limpeza de Dados em Stream

e-book

01:54

Projeto 4

Windowed Operations e Stateful Processing

e-book

02:15

Projeto 4

Construindo o Módulo de Processamento de Stream - Parte 1/7

video

04:28

Projeto 4

Construindo o Módulo de Processamento de Stream - Parte 2/7

video

07:29

Projeto 4

Construindo o Módulo de Processamento de Stream - Parte 3/7

video

06:14

Projeto 4

Construindo o Módulo de Processamento de Stream - Parte 4/7

video

06:55

Projeto 4

Construindo o Módulo de Processamento de



Projeto 4

Windowed Operations e Stateful Processing

Windowed Operations e Stateful Processing são dois conceitos importantes no processamento de streams no PySpark Streaming, permitindo agregar e acompanhar dados ao longo do tempo:



?

Suporte

?

Suporte



 Operações em janela:

As **operações em janela** permitem processar e adicionar dados que chegam ao longo de uma janela de tempo específica.

Isso é útil quando você quer analisar o comportamento de dados em um intervalo de tempo contínuo, como calcular a média, soma ou contagem de eventos dentro de uma janela de segundos ou minutos.

Os principais aspectos dessas operações são:

1. **Janela de Tempo:** Defina o intervalo de tempo em que os dados serão agrupados e processados. Por exemplo, uma janela de 5 minutos significa que os dados recebidos em um intervalo de 5 minutos serão processados juntos.

2. **Deslização da Janela:** Consulte o intervalo em que a janela será recalculada. Por exemplo, se uma janela tiver uma penetração de 2 minutos, novos dados serão agregados e processados a cada 2 minutos.

3. **Aplicação:** Operações comuns em janelas incluem contagens, somas, médias ou qualquer operação de agregação. Isso permite, por exemplo, monitorar tendências ou padrões que se repetem em intervalos regulares de tempo.

?

Suporte

?

Suporte

 Processamento com estado:

O **Stateful Processing** permite manter o estado entre microlotes, ou seja, você pode rastrear e acumular informações ao longo do tempo, o que é essencial para determinados tipos de análise de fluxos, como contagem cumulativa ou detecção de padrões que se estendem além de uma única janela de tempo.

1. **Atualização de Estado (updateStateByKey):** Permite manter um estado associado a cada chave de um stream. Por exemplo, se você estiver contando eventos por usuário, poderá atualizar a contagem de eventos de cada usuário à medida que novos dados chegarem. Esse estado é suspensão entre microlotes.

2. **MapWithState:** Uma API mais avançada que permite rastrear estados complexos e associar transformações adicionais a cada chave. Isso oferece liberdade para definir o que significa "estado" para sua aplicação, como a contagem de eventos, valores acumulados ou até mesmo estados personalizados definidos pelo desenvolvedor.

3. **Checkpointing:** Em Stateful Processing é importante usar checkpoints para garantir que, em caso de falhas, o estado possa ser recuperado e o processamento continue sem perda de dados. Isso envolve salvar periodicamente o estado atual em um armazenamento resiliente.

?

Suporte

?

Suporte

Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

?

Suporte

?

Suporte