



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

Configurações do Consumidor e Controle de Offset

PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

No Kafka, as configurações do consumidor e o controle de offset são fundamentais para determinar como os consumidores lêem mensagens de tópicos e acompanham o progresso da leitura. O offset é um identificador numérico exclusivo que representa a posição de uma mensagem dentro de uma partição de um tópico. Ele funciona como um índice que permite localizar e rastrear mensagens armazenadas no Kafka.

Alguns dos principais parâmetros de configuração são:

group.id: Identifica o grupo de consumidores. Consumidores no mesmo grupo dividem o trabalho de consumir mensagens de um tópico, garantindo que cada partição seja atribuída a apenas um consumidor do grupo.


auto.offset.reset: Define o comportamento ao iniciar o consumo em um tópico:

- "earliest": Começa a consumir do início (primeiro offset disponível).
- "latest": Começa a consumir apenas mensagens novas.
- "none": Gera erro se não houver um offset previamente salvo.

enable.auto.commit: Controla se o consumidor deve salvar automaticamente os offsets após processar mensagens:

- true: O Kafka salva automaticamente o offset (padrão).
- false: O consumidor gerencia manualmente o commit, dando maior controle.

fetch.min.bytes e **fetch.max.wait.ms:** Controlam o comportamento de busca de mensagens para equilibrar latência e eficiência.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.