



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

Projeto 5 Extração, Processamento e Armazenamento de Dados em Tempo Real com Kafka e Spark Streaming




PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming



Neste projeto vamos construir um Kafka producer para produzir dados em tempo real e enviar para um tópico. Vamos simular dados extraídos do acesso a um web site em tempo real. Então criaremos um Kafka consumer com o Spark Streaming para consumir e processar os dados em tempo real e então armazenar os dados processados no HDFS em formato Parquet.

Nossa equipe fez um grande esforço para preparar o material de forma que você possa reproduzir na sua máquina e estudar as ferramentas e técnicas. Mas este projeto é pesado e pode ser desafiador reproduzir na sua máquina. Feche todo e qualquer aplicativo que não seja Docker e terminal/prompt de comando e se necessário desligue o container do Kafka UI e/ou um dos Spark Workers. Fique à vontade para estudar a documentação das ferramentas e otimizar o que for possível em termos de configuração.

Os arquivos estão ao final do capítulo. Assista primeiro as aulas e somente depois tente reproduzir o projeto, se desejar. Bons estudos.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.