



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

O Kafka é Um Banco de Dados?


PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

O Apache Kafka não é um banco de dados. Ele é uma plataforma de streaming de dados distribuída projetada para lidar com o processamento e transmissão de grandes volumes de informações em tempo real. Seu principal objetivo é permitir que sistemas diferentes se comuniquem de forma eficiente por meio de um modelo de publicação/assinatura, onde dados são produzidos e consumidos de maneira assíncrona.

O Kafka é usado principalmente para ingestão de dados, processamento em tempo real e integração entre sistemas. Ele armazena mensagens em tópicos por um período configurado, mas essa capacidade não o torna um banco de dados tradicional, pois:

- Ele não oferece suporte a consultas avançadas como SQL em bancos relacionais ou busca indexada como em bancos NoSQL.
- Não possui garantia de consistência transacional como sistemas ACID (Atomicidade, Consistência, Isolamento, Durabilidade).
- Os dados são armazenados de forma efêmera, dependendo do tempo ou tamanho configurado.

Embora existam ferramentas como Kafka Streams e KSQL para processar dados diretamente no Kafka, seu propósito é complementar bancos de dados e outros sistemas de armazenamento, e não substituí-los.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.