



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

O Que São Mensagens no Kafka?

PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

No Apache Kafka, uma mensagem é a unidade básica de dados que é escrita e lida de um tópico. Cada mensagem contém informações que são transmitidas de um produtor (quem envia os dados) para um consumidor (quem recebe os dados).

Uma mensagem no Kafka possui os seguintes componentes principais:

Chave (Key): Um identificador opcional que pode ser usado para particionamento. Mensagens com a mesma chave serão enviadas para a mesma partição, o que pode ajudar a organizar dados relacionados.


Valor (Value): O conteúdo principal da mensagem, que pode ser qualquer dado, como texto, JSON, XML, binário ou qualquer outro formato.

Timestamps: Informações de tempo associadas à mensagem, como o momento em que foi criada ou registrada no Kafka.

Cabeçalhos (Headers): Dados opcionais que podem ser usados para transportar informações adicionais sobre a mensagem, como metadados.

As mensagens são armazenadas em tópicos dentro do Kafka. Cada tópico é dividido em partições, onde as mensagens são armazenadas em ordem. Essa estrutura facilita a escalabilidade e o consumo paralelo das mensagens pelos consumidores.

Mensagens no Kafka são imutáveis e permanecem disponíveis no sistema por um período configurado (por exemplo, alguns dias) ou até atingir um limite de espaço, mesmo depois de terem sido consumidas. Isso permite casos de uso como processamento de eventos, streaming em tempo real e replay de dados.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.