

Trilha

Fórum

✓ pdf

Projeto 5 - Configurações do Consumidor e Controle de Offset

✓ videolivro

Projeto 5 - Construindo o Kafka Spark Consumer - Parte 1/3

00:23

▶ video

Projeto 5 - Construindo o Kafka Spark Consumer - Parte 2/3

04:35

✓ videolivro

Projeto 5 - Construindo o Kafka Spark Consumer - Parte 3/3

01:33

Projeto 5 - Grupos de Consumidores e Balanceamento de Carga

pdf

▶ video

Projeto 5 - Reconstruindo o Cluster com Docker - Parte 1/2

01:36

▶ video

Projeto 5 - Reconstruindo o Cluster com Docker - Parte 2/2

02:04

▶

Projeto 5 - Executando Extração, Processamento e




Projeto 5

Construindo o Kafka Spark Consumer

Parte 3/3

No Spark Streaming, watermark é uma técnica usada para gerenciar dados atrasados (ou dados fora de ordem) em fluxos de streaming. Ele ajuda a lidar com situações em que dados com carimbos de data/hora antigos podem chegar após o processamento principal, permitindo que o sistema defina uma janela de tolerância para esses atrasos.

A função withWatermark define uma "marca d'água" que especifica quanto tempo o Spark deve esperar por dados atrasados antes de considerar que o estado correspondente pode ser descartado.



?

Suporte

?

Suporte



Como funciona a marca d'água?

- Atraso tolerado: Uma marca d'água define uma duração de atraso tolerável (por exemplo, 10 segundos).
- Descartar dados antigos: O Spark usa a marca d'água para determinar quando você pode descartar o estado de eventos mais antigos do que o atraso definido.
- Manter a eficiência: Isso ajuda a liberar memória e recursos, já que estados necessários para dados antigos são removidos.

Cenário de Uso

Imagine que você está processando cliques de usuários e agrupando por janelas de 10 segundos. Se você definir uma marca d'água de "10 segundos":

- O Spark aceitará e processará eventos atrasados até 10 segundos após o final da janela.
- Se um evento com timestamp antigo (mais de 10 segundos além do final da janela) chegar, ele será descartado e não contribuirá para a agregação.

Benefícios do Watermark


- Gerenciamento de dados fora de ordem: Ele permite processar dados atrasados sem comprometer a precisão.
- Economia de recursos: Remove estados de janelas de tempo que não são mais relevantes, reduzidos o uso de memória.
- Controle de latência: Garante que o processamento contínuo não seja atrasado indefinidamente por causa de dados fora de ordem.

?

Suporte

?

Suporte



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

?

Suporte

?

Suporte

?

Suporte

?

Suporte

