



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

Streams API do Kafka

PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

A Streams API do Kafka é uma biblioteca específica do Apache Kafka, projetada para criar aplicações e microservices que processam fluxos de dados em tempo real. Ela permite processar, transformar e analisar dados em fluxo (streaming) diretamente dos tópicos do Kafka, sem a necessidade de usar ferramentas externas como o Apache Spark ou o Apache Flink.

Ela é implementada em Java e Scala e se integra nativamente ao Kafka, fornecendo uma abstração de alto nível para lidar com fluxos de dados e operações relacionadas. Algumas das principais características da Streams API incluem:

Processamento de Fluxo em Tempo Real: Os dados podem ser consumidos, processados e enviados a outros tópicos ou sistemas externos em tempo real.

Estado Local: Suporte para operações com estado, como agregações, joins e reduções, com a possibilidade de manter estados localmente nos nós da aplicação.


Escalabilidade: As aplicações construídas com a Streams API podem ser escaladas horizontalmente, aproveitando o particionamento do Kafka.

Abstrações de Alto Nível: Fornece interfaces como KStream (fluxo de dados), KTable (representação de dados agregados) e GlobalKTable (uma tabela global replicada em todos os nós).

Garantia de Precisão: Suporte para processamento "exactly-once", garantindo que os dados sejam processados apenas uma vez, mesmo em cenários de falhas.

Operações Comuns: Inclui operações como filtragem, mapeamento, agregação, junção de streams e transformação de dados.

A Streams API é útil para criar aplicações que precisam processar dados em tempo real de maneira confiável e escalável, como sistemas de recomendação, monitoramento de fraudes, análise de logs, entre outros.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.