

PySpark e Apache Kafka para processamento de dados em lote e streaming

81%

Trilha

Fórum

- Projeto 7 - Executando o Real-Time ETL Stack com Airflow, Kafka, PySpark e Cassandra - Parte 1/3

video03:29
- Projeto 7 - Executando o Real-Time ETL Stack com Airflow, Kafka, PySpark e Cassandra - Parte 2/3

video02:20
- Projeto 7 - Executando o Real-Time ETL Stack com Airflow, Kafka, PySpark e Cassandra - Parte 3/3

video04:05
- Projeto 7 - Conclusão

video03:52
- Otimizações de Desempenho no Stack PySpark-Kafka

videolivro01:52
- Monitoramento de Pipelines em Tempo Real

videolivro02:18
- Arquivos Usados Neste Capítulo

pdf
- Bibliografia, Referências e Links Úteis

pdf

10 Monitorando o Kafka Cluster em Tempo Real



Monitoramento de Pipelines em Tempo Real

O monitoramento de pipelines em tempo real é essencial para garantir a eficiência, confiabilidade e desempenho dos fluxos de dados em sistemas distribuídos e ambientes de processamento contínuo. Ele envolve observação, coleta, análise e alerta sobre detalhes e eventos relevantes enquanto os pipelines estão em execução.

Principais Aspectos do Monitoramento de Dutos em Tempo Real

1. Métricas Essenciais

Taxa de Processamento (Throughput): Volume de dados processados por unidade de tempo, medido em mensagens/segundo ou bytes/segundo.

Latência: Tempo necessário para processar uma unidade de dados, desde a entrada até a saída.

🔍 Suporte

🔍 Suporte



Erros e Falhas: Taxa de erros no pipeline ou falhas em tarefas específicas.

Utilização de Recursos: Monitoramento de CPU, memória, largura de banda de rede e armazenamento.

Estado de Checkpoints: Indicadores de consistência e recuperação, especialmente em dutos de processamento contínuo.

2. Técnicas e Ferramentas

Logs em Tempo Real: Registros detalhados de eventos para identificar problemas. Ferramentas como o Logstash podem ajudar a consolidar logs.

Painéis de Visualização: Dashboards criados com ferramentas como Grafana, Kibana ou Prometheus, que oferecem insights em tempo real com gráficos e alertas.

Alertas Automatizados: Configuração de notificações para eventos críticos, como falhas, latências elevadas ou manipulação de desempenho.

Rastreamento: Rastreamento de eventos de ponta a ponta para identificar gargalos ou erros (ferramentas como Jaeger ou Zipkin).

3. Monitoramento Específico para Dutos

Kafka: Utilize ferramentas como Kafka Manager, Confluent Control Center ou integrações integradas do JMX para monitorar offset lag, throughput de detalhes e saúde do cluster.

Apache Spark: O Spark UI permite acompanhar a execução de tarefas, uso de memória e estado de RDDs. No caso de Streaming Estruturado, o monitoramento inclui dados sobre taxas de microlotes e latência.

4. Práticas Recomendadas

SLAs/SLIs: Estabeleça limites claros para definir detalhes como latência, disponibilidade e throughput para avaliar a saúde do pipeline.

Coleta Centralizada: Consolida métricas e logs de diferentes componentes (por exemplo, Kafka, Spark, Flink) em um único local para análise.

Escalabilidade do Monitoramento: Certifique-se de que o sistema de monitoramento seja escalável, apoiando o crescimento do pipeline.

Testes de Carga: Realize testes regulares para identificar pontos de falha em condições de alta demanda.

5. Benefícios

Prevenção de Problemas: Identificação proativa de gargalos e falhas antes que afetem a produção.

Otimização Contínua: Insights que permitem ajustar e otimizar a arquitetura e as configurações do pipeline.

Confiabilidade e SLA: Garantia de que os pipelines atendem aos requisitos de tempo real definidos pelo negócio.

O monitoramento eficaz em tempo real não apenas melhora a operação dos pipelines, mas também ajuda a manter a integridade dos dados e a experiência do usuário final.


🔍 Suporte

🔍 Suporte



🔍 Suporte

🔍 Suporte



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.