



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

O Que é e Quando Usar Apache Cassandra?



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

O Apache Cassandra é um sistema de banco de dados NoSQL distribuído altamente escalável e projetado para gerenciar grandes volumes de dados em vários datacenters, com alta disponibilidade e sem pontos únicos de falha. Ele é baseado em um modelo de armazenamento orientado a colunas, o que o torna ideal para cenários que exigem grande capacidade de leitura e escrita de dados com baixa latência.

Principais Características:

- Desempenho e Escalabilidade: Manipula grandes volumes de dados distribuídos de forma horizontal em vários nós.
- Alta Disponibilidade: Projetado para garantir que o sistema continue funcionando mesmo com falhas de hardware ou rede.
- Modelo de Consistência Configurável: Permite ajustar o equilíbrio entre consistência, disponibilidade e tolerância a partições.
- Sem Ponto Único de Falha: Cada nó no cluster é igual (arquitetura "peer-to-peer").
- Replicações Multidatacenter: Suporte nativo para replicar dados em várias regiões geográficas.

Quando Usar o Apache Cassandra?

1. Cenários com Grande Escalabilidade e Alta Disponibilidade

- Aplicações que precisam lidar com um volume massivo de dados distribuídos globalmente, como plataformas de mídia social ou aplicativos de IoT.
- Necessidade de manter o sistema operacional mesmo durante falhas em servidores ou datacenters.

2. Requisitos de Alta Taxa de Escrita

- Aplicativos que geram grandes quantidades de dados continuamente, como logs de atividades, dispositivos IoT ou sistemas de monitoramento.

3. Aplicações com Baixa Latência

- Casos em que a leitura e gravação de dados precisam ser extremamente rápidas, como sistemas de recomendação em tempo real, mecanismos de busca ou catálogos de produtos.

4. Sistemas com Dados Replicados Globalmente

- Quando é necessário que os dados estejam disponíveis em múltiplas regiões para reduzir a latência percebida por usuários distribuídos geograficamente.


PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

5. Modelos de Dados Orientados a Colunas

- Casos em que os dados são mais adequadamente organizados como coleções de colunas (em vez de tabelas relacionais), como registros de logs, perfis de usuários ou sensores IoT.

Quando Não Usar o Apache Cassandra?

- Transações Complexas e Fortemente Consistentes: Para aplicações que exigem transações ACID complexas ou joins, bancos de dados relacionais (como PostgreSQL ou MySQL) podem ser mais adequados.
- Consultas Ad Hoc: Cassandra não é otimizado para consultas complexas com múltiplos filtros ou joins; ele funciona melhor com esquemas de dados previamente definidos e otimizados.
- Baixo Volume de Dados: Para pequenos sistemas com baixa necessidade de escalabilidade, Cassandra pode ser um exagero e uma solução mais simples pode ser melhor.
- Análises Complexas: Se a principal necessidade é análise de dados, soluções como Apache Hive, Presto ou bancos analíticos (como Snowflake) são mais indicadas.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.