



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

Projeto 7 Real-Time ETL Stack com Airflow, Kafka, PySpark e Cassandra




PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming



Este projeto explora a construção de uma stack de ETL em tempo real, integrando ferramentas modernas para processamento de dados. O Apache Airflow será usado para orquestração de workflows, enquanto o Kafka será usado para gerenciar o streaming de dados em tempo real. O PySpark será utilizado para processamento distribuído de dados e o Cassandra servirá como banco de dados NoSQL de alta performance para armazenamento.

Todo o pipeline será criado para funcionar de forma automatizada.

Os arquivos estão ao final do capítulo. Bons estudos.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.