



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

Balanceamento de Partições Entre Nodes de Clusters Kafka


PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

O balanceamento de partições em clusters Kafka ocorre para distribuir uniformemente a carga de trabalho entre os brokers, otimizando o uso de recursos, como CPU, memória e armazenamento. Esse processo pode ser automático ou manual, dependendo da configuração e da necessidade do administrador.

Cada partição de um tópico no Kafka possui um líder e, opcionalmente, réplicas. O broker que contém a partição líder é responsável por gerenciar toda a leitura e escrita para essa partição, enquanto os brokers com réplicas sincronizam dados a partir do líder para garantir alta disponibilidade. O balanceamento visa garantir que nenhuma partição ou liderança fique concentrada em um único broker, evitando sobrecarga em um nó específico.

O Kafka implementa o balanceamento por meio do Controlador, que é um broker eleito para gerenciar metadados e coordenação do cluster. Quando um novo broker é adicionado ou removido do cluster, o controlador redistribui as partições e réplicas, ajustando as lideranças para manter o equilíbrio.

O processo de balanceamento leva em consideração fatores como o número de partições, o volume de dados processado e a configuração de replicação. A redistribuição é feita sem interrupção significativa do serviço, garantindo que os consumidores e produtores continuem funcionando enquanto os dados são movimentados entre os brokers.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.