



PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

Monitoramento de Performance em Clusters Kafka

PySpark e Apache Kafka Para Processamento de Dados em Batch e Streaming

O monitoramento de performance em clusters Kafka é essencial para manter a confiabilidade, otimizar o desempenho e identificar problemas antes que afetem os consumidores e produtores. Esse processo envolve o rastreamento de métricas críticas relacionadas ao cluster, aos brokers, às partições e à comunicação entre clientes e servidores.

Métricas do Broker: Os brokers são o núcleo do cluster e monitorar seu desempenho é essencial. Métricas como uso de CPU, memória e disco fornecem insights sobre a saúde geral. Métricas específicas, como MessagesInPerSec e BytesInPerSec, indicam a taxa de mensagens e dados que o broker está processando. Além disso, a latência de replicação e o tempo de resposta às solicitações ajudam a identificar gargalos.


Métricas de Partições e Tópicos: É fundamental monitorar o equilíbrio da carga entre as partições e brokers. Métricas como o número de partições por broker, o tamanho das filas (log size) e o tempo de retenção ajudam a garantir que os dados sejam processados e armazenados de forma eficiente. A discrepância no tamanho das partições pode indicar um problema de balanceamento.

Estado das Réplicas: O Kafka fornece métricas sobre réplicas sincronizadas (ISR) e réplicas fora de sincronia (OSR). Um aumento nas OSRs pode sinalizar problemas de conectividade, desempenho ou falhas em brokers. Monitorar o tempo necessário para réplicas recuperarem a sincronização também é essencial para avaliar a resiliência do cluster.

Desempenho da Rede: A comunicação entre brokers e entre clientes e brokers depende de uma rede eficiente. Métricas como NetworkProcessorAvgIdlePercent indicam a carga nos processadores de rede dos brokers. Também é importante monitorar o tráfego de entrada e saída, a latência de rede e o número de conexões ativas para garantir que a infraestrutura esteja dimensionada corretamente.

Latência de Produção e Consumo: A latência observada pelos produtores ao enviar mensagens e pelos consumidores ao processá-las é uma métrica-chave. Valores elevados podem indicar problemas de sobrecarga, retenção de mensagens em filas ou latência de replicação.

Ferramentas de Monitoramento: O Kafka expõe métricas detalhadas por meio do JMX (Java Management Extensions), que podem ser integradas a ferramentas como Prometheus, Grafana, Datadog ou Elastic Stack. Essas ferramentas permitem a criação de dashboards personalizados e alertas baseados em thresholds configurados para métricas críticas.



Equipe DSA

Muito Obrigado!

Continue Trilhando Uma Excelente Jornada de Aprendizagem.