Projeto 3 - Concatenando os Datasets e Preparando o Dataset Final
video 04:45

Projeto 3 - Engenharia de Atributos
videobook 00:29

Projeto 3 - Pré-Processamento com String Indexer e One Hot Encoder - Parte 1/2
videobook 01:03

Projeto 3 - Pré-Processamento com String Indexer e One Hot Encoder - Parte 2/2
video 03:03

Projeto 3 - Criando o Pipeline de Pré-Processamento
video 05:41

Projeto 3 - Ajustando o Número de Partições
videobook 01:19

Projeto 3 - Pipeline de Treinamento do Modelo de IA com PySpark em Ambiente Distribuído - Parte 1/5
video 02:55

Projeto 3 - Pipeline de Treinamento do Modelo de IA com PySpark em Ambiente Distribuído - Parte 2/5
video 04:48

Data Science Academy

Projeto 3
Ajustando o Número de Partições

O conceito de particionamento no Spark refere-se ao processo de dividir grandes conjuntos de dados em partes menores, chamadas de partições, que podem ser processadas de forma distribuída entre diferentes nós de um cluster. Cada partição contém uma fração dos dados e é processada de forma independente, o que permite que o Spark escale o processamento de dados de forma eficiente.

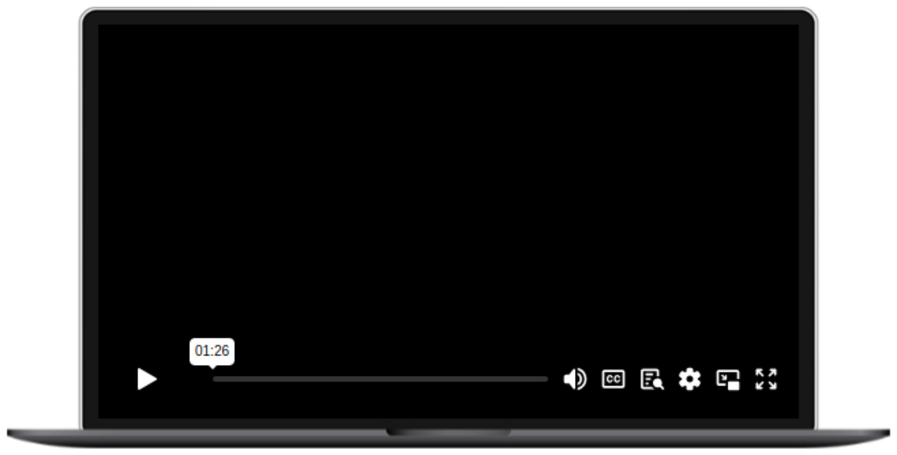
Aqui estão os principais pontos sobre o particionamento no Spark:

Distribuição de dados: Cada partição pode ser processada por um nó separado no cluster Spark. Isso permite que operações como leitura, transformação e escrita de dados sejam executadas de maneira paralela, aumentando a velocidade de processamento.

Controle de particionamento: O número de partições pode ser configurado. Particionar adequadamente os dados é importante, pois um número muito pequeno de partições pode sobrecarregar nós individuais, enquanto um número muito grande pode introduzir sobrecarga de gerenciamento.

Operações baseadas em partições: O Spark otimiza operações baseadas no particionamento. Por exemplo, em operações de join ou shuffle, o Spark pode reorganizar os dados em partições específicas para minimizar a quantidade de dados que precisam ser movimentados entre nós.

Resiliência: O particionamento facilita a resiliência no Spark. Se um nó falha durante o processamento, apenas as partições que estavam sendo processadas por aquele nó precisam ser reprocessadas por outro nó, em vez de reiniciar todo o trabalho.



Equipe DSA

Continue trilhando uma excelente jornada de aprendizagem.

Suporte
Suporte